

UNIVERSIDADE DE SÃO PAULO

Instituto de Ciências Matemáticas e de Computação

**Integrando Ciência da Informação e Processamento
em Linguagem Natural: Uma abordagem baseada
em frameworks para facilitação do
compartilhamento de conhecimento organizacional**

Bruno Henrique Brito

Monografia - MBA em Inteligência Artificial e Big Data

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Bruno Henrique Brito

Integrando Ciência da Informação e Processamento em Linguagem Natural: Uma abordagem baseada em frameworks para facilitação do compartilhamento de conhecimento organizacional

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Prof. Dr. Roney L. de S. Santos

Versão original

São Carlos

2025

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

B862i Brito, Bruno Henrique
Integrando Ciência da Informação e Processamento
em Linguagem Natural: Uma abordagem baseada em
frameworks para facilitação do compartilhamento de
conhecimento organizacional / Bruno Henrique Brito;
orientador Roney Santos. -- São Carlos, 2025.
61 p.

Trabalho de conclusão de curso (MBA em
Inteligência Artificial e Big Data) -- Instituto de
Ciências Matemáticas e de Computação, Universidade
de São Paulo, 2025.

1. PLN. 2. Ciência da Informação. 3. Grafos. 4.
Gestão do conhecimento. 5. LLM. I. Santos, Roney,
orient. II. Título.

Bruno Henrique Brito

**Integrating Information Science and Natural Language
Processing: A framework-based approach to facilitate
organizational knowledge sharing.**

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Roney L. de S. Santos

Original version

São Carlos

2025

Em um mundo onde a velocidade muitas vezes ofusca a qualidade e a pressão por resultados imediatos nos leva a buscar atalhos, somos constantemente cobrados por meras “sopas de letrinhas” — por ferramentas da moda e frameworks vazios.

Enquanto muitos modelos de linguagem preveem a próxima palavra com base em uma probabilidade instantânea, este trabalho é fruto de um processo diferente. Foram vinte anos de vivências, erros e acertos que me moldaram como profissional e pessoa, e me prepararam para prever cada palavra que viria a seguir. E foi ao longo de seis meses de dedicação que, finalmente, pude expressar essa jornada.

A verdadeira solução não reside em um simples pacote ou em uma tecnologia passageira. Ela emerge da lógica, da teoria e do experimento. Ela é moldada pela curiosidade, pela perseverança e, acima de tudo, pela **Força da Ciência** — a Força do conhecimento profundo.

Que a sua busca pela verdade seja a bússola que guia suas ações e que a sua inteligência seja a luz que ilumina o caminho. E que, ao som da sinfonia que me acompanhou, a Força esteja com todos aqueles que se atrevem a inovar e a construir um futuro mais inteligente. *Dedico este trabalho a todos os profissionais que, com paixão e resiliência, dedicam suas vidas a estudar, a aprender e a usar a inteligência para construir soluções inovadoras, corretas e compreensíveis.*

Em um mundo onde a velocidade muitas vezes ofusca a qualidade e a pressão por resultados imediatos nos leva a buscar atalhos, somos constantemente cobrados por meras “sopas de letrinhas” — por ferramentas da moda e frameworks vazios.

Enquanto muitos modelos de linguagem preveem a próxima palavra com base em uma probabilidade instantânea, este trabalho é fruto de um processo diferente. Foram vinte anos de vivências, erros e acertos que me moldaram como profissional e pessoa, e me prepararam para prever cada palavra que viria a seguir. E foi ao longo de seis meses de dedicação que, finalmente, pude expressar essa jornada.

*A verdadeira solução não reside em um simples pacote ou em uma tecnologia passageira. Ela emerge da lógica, da teoria e do experimento. Ela é moldada pela curiosidade, pela perseverança e, acima de tudo, pela **Força da Ciência** — a Força do conhecimento profundo.*

Que a sua busca pela verdade seja a bússola que guia suas ações e que a sua inteligência seja a luz que ilumina o caminho. E que, ao som da sinfonia que me acompanhou, a Força esteja com todos aqueles que se atrevem a inovar e a construir um futuro mais inteligente.

AGRADECIMENTOS

Agradeço a minha esposa, Carol. Se não fosse por ela me fazer pensar tanto, eu não estaria aqui escrevendo.

Ao meu orientador, Prof. Dr. Roney, pelas conversas, dicas e interações.

A George Lucas e John Williams pela inspiração. Ao som (e pensamento) de Star wars, foi possível encontrar toda a Força para vencer o cansaço e as barreiras e desenvolver essa pesquisa.

A todos meus amigos e amigas nerds que discutem comigo esse tema incansavelmente, mesmo com a minha chatice.

“Desista da ideia de me fazer desistir. Este é o meu jeito ninja! ”
Jiraya Sensei

RESUMO

Brito, B. **Modelo para teses e dissertações em LaTeX utilizando o Pacote USPSC para o ICMC**. 2025. 87 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

Esta monografia aborda o desafio de transformar a vasta quantidade de informações em conhecimento acionável nas organizações, explorando a integração entre a **Ciência da Informação (CI)** e o **Processamento de Linguagem Natural (PLN)**. O principal objetivo foi propor uma abordagem que otimize a circulação do conhecimento, da absorção ao compartilhamento, utilizando princípios de governança, segurança e ética informacional. A pesquisa se fundamenta em modelos como o **SECI**, para a gestão do conhecimento, e em frameworks de gestão de dados como o **DAMA-DMBOK** e o **CRISP-DM**. Para validar a proposta, foi desenvolvido um protótipo com um **grafo de conhecimento** que atua como uma camada inteligente, centralizando metadados e relações semânticas. O protótipo é capaz de traduzir **perguntas em linguagem natural em consultas SQL**, demonstrando a viabilidade de sistemas que utilizam o contexto semântico e metadados para gerar respostas precisas e confiáveis. Os resultados experimentais, baseados em casos de uso simulados, confirmaram a capacidade do sistema em construir consultas complexas e em identificar a ausência de conexões de dados. O estudo contribui ao demonstrar a viabilidade de utilizar grafos de conhecimento como um *proxy* inteligente, o que aumenta a segurança e a privacidade, pois apenas metadados e esquemas são expostos aos **Large Language Models (LLMs)**, e não os dados sensíveis. Conclui-se que a união entre a CI e o PLN é um caminho eficaz para otimizar a gestão do conhecimento, traduzindo a intenção do usuário em consultas acionáveis e facilitando a internalização do conhecimento por meio de explicações detalhadas.

Palavras-chave: Gestão do conhecimento. PLN. Grafos de conhecimento. Ciência da informação. LLM. Text-to-SQL.

ABSTRACT

Brito, B. **Model for thesis and dissertations in $\LaTeX$ using the USPSC Package to the ICMC**. 2025. 87 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

This monograph addresses the challenge of transforming vast amounts of information into actionable knowledge within organizations, exploring the integration of **Information Science (IS)** and **Natural Language Processing (NLP)**. The main objective was to propose an approach that optimizes knowledge circulation, from absorption to sharing, by applying principles of governance, security, and information ethics. The research is based on models such as **SECI** for knowledge management and on data management frameworks like **DAMA-DMBOK** and **CRISP-DM**. To validate this approach, a prototype was developed using a **knowledge graph** that acts as an intelligent layer, centralizing metadata and semantic relationships. This prototype is capable of **translating natural language questions into SQL** queries, demonstrating the viability of systems that use semantic context and metadata to generate accurate and reliable answers. The experimental results, based on simulated use cases, confirmed the system's ability to build complex queries and to identify the absence of data connections. The study contributes by showing the feasibility of using knowledge graphs as an intelligent *proxy*, which enhances security and privacy since only metadata and schemas are exposed to **Large Language Models (LLMs)**, not sensitive data. It is concluded that the synergy between Information Science and NLP is an effective path to optimize knowledge management, translating user intent into actionable queries and facilitating knowledge internalization through detailed explanations.

Keywords: Knowledge management . NLP. Knowledge graph. Information Science. LLM. Text-to-SQL.

LISTA DE FIGURAS

Figura 1 – Grafo de conhecimento (Fonte: Neo4J)	35
Figura 2 – Representação de uma Ontologia (Fonte: Enterprise Knowledge)	37
Figura 3 – Mandala de competências do DMBOK (Fonte: DMBOK)	39
Figura 4 – O ciclo de vida da mineração de dados (Fonte: IBM)	41
Figura 5 – Arquitetura de solução em alto nível (Fonte: Autor)	46
Figura 6 – Arquitetura de solução em nível detalhado (Fonte: Autor)	46
Figura 7 – Socialização e captura de conhecimento tácito (Fonte: Autor)	47
Figura 8 – Externalização do conhecimento (Fonte: Autor)	48
Figura 9 – Grafo de conhecimento (Fonte: Autor)	49
Figura 10 – Combinação e Internalização do conhecimento (Fonte: Autor)	50
Figura 11 – Desenho de solução de componentes (Fonte: Autor)	53
Figura 12 – Trecho do grafo com os principais componentes (Fonte: Autor)	54
Figura 13 – Caso 1 - Elementos relevantes do grafo (Fonte: Autor)	56
Figura 14 – Caso 1 - Query gerada pelo LLM (Fonte: Autor)	57
Figura 15 – Caso 1 - Retorno da consulta gerada pelo LLM (Fonte: Autor)	59
Figura 16 – Caso 1 - Retorno da consulta gabarito (Fonte: Autor)	59
Figura 17 – Caso 2 - Elementos relevantes do grafo (Fonte: Autor)	60
Figura 18 – Caso 2 - Query gerada pelo LLM (Fonte: Autor)	60
Figura 19 – Caso 3 - Elementos relevantes do grafo (Fonte: Autor)	61
Figura 20 – Caso 3 - Query gerada pelo LLM (Fonte: Autor)	61
Figura 21 – Caso 4 - Elementos relevantes do grafo (Fonte: Autor)	62
Figura 22 – Caso 4 - Query gerada pelo LLM (Fonte: Autor)	62
Figura 23 – Caso 4 - Retorno da consulta gerada pelo LLM (Fonte: Autor)	64
Figura 24 – Caso 4 - Retorno da consulta gabarito (Fonte: Autor)	64
Figura 25 – Caso 5 - Elementos relevantes do grafo (Fonte: Autor)	65
Figura 26 – Caso 5 - Query gerada pelo LLM (Fonte: Autor)	65
Figura 27 – Caso 6 - Elementos relevantes do grafo (Fonte: Autor)	66
Figura 28 – Caso 6 - Query gerada pelo LLM (Fonte: Autor)	67
Figura 29 – Caso 6 - Retorno da consulta gerada pelo LLM (Fonte: Autor)	69
Figura 30 – Caso 6 - Retorno da consulta gabarito (Fonte: Autor)	69
Figura 31 – Caso 7 - Elementos relevantes do grafo (Fonte: Autor)	70
Figura 32 – Caso 7 - Query gerada pelo LLM (Fonte: Autor)	70
Figura 33 – Caso 7 - Retorno da consulta gerada pelo LLM (Fonte: Autor)	72
Figura 34 – Caso 7 - Retorno da consulta gabarito (Fonte: Autor)	73
Figura 35 – Caso 8 - Elementos relevantes do grafo (Fonte: Autor)	74
Figura 36 – Caso 8 - Query gerada pelo LLM (Fonte: Autor)	74

Figura 37 – Caso 9 - Elementos relevantes do grafo (Fonte: Autor) 75

Figura 38 – Caso 9 - Query gerada pelo LLM (Fonte: Autor) 75

Figura 39 – Caso 9 - Retorno da consulta gerada pelo LLM (Fonte: Autor) 77

Figura 40 – Caso 9 - Retorno da consulta gabarito (Fonte: Autor) 77

LISTA DE TABELAS

Tabela 1	–	Caso de uso 1: Explicação LLM	58
Tabela 2	–	Caso de uso 4: Explicação LLM	63
Tabela 3	–	Caso de uso 6: Explicação LLM	68
Tabela 4	–	Caso de uso 7: Explicação LLM	71
Tabela 5	–	Caso de uso 9: Explicação LLM	76
Tabela 6	–	Casos de uso e resultados	78
Tabela 6	–	Casos de uso e resultados	79

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

CI	Ciência da Informação
CRISP-DM	Cross-Industry Standard Process for Data Mining
DAMA	Data Management Association
DMBOK	Data Management Body of Knowledge
DDD	Domain-Driven Design
IA	Inteligência Artificial
IBM	International Business Machines Corporation
LGPD	Lei Geral de Proteção de Dados
LLM	Large Language Model
ODPS	Open Data Product Specification
OWL	Web Ontology Language
PLN	Processamento de Linguagem Natural)
PoC	Proof of Concept
RDF	Resource Description Framework
SECI	Socialização, Externalização, Combinação, Internalização
SQL	Structured Query Language
SPSS	Statistical Package for the Social Sciences
USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos
W3C	World Wide Web Consortium
YAML	Yet another markup Language

SUMÁRIO

1	INTRODUÇÃO	27
2	FUNDAMENTAÇÃO TEÓRICA	31
2.1	Ciência da Informação e Ecologia Informacional	31
2.2	Gestão do Conhecimento e Modelos de Transformação	31
2.3	Arquitetura e Contextos de Informação	33
2.4	Processamento em Linguagem Natural	33
2.5	Grafos de Conhecimento	35
2.5.1	Definição e Propósito	35
2.6	Ontologias e Representação do Conhecimento	36
2.7	<i>Frameworks</i> de Governança e Gestão de informação	38
2.7.1	DAMA-DMBOK e a DAMA <i>International</i>	38
2.7.2	CRISP-DM e seu Consórcio Original	40
2.7.3	<i>Open Data Product Specification</i> (ODPS)	40
2.8	Considerações Finais	43
3	METODOLOGIA	45
3.1	Abordagem Metodológica	45
3.2	Proposta de Desenvolvimento	45
3.2.1	Etapa 1: Captura de Dados e Conhecimento	45
3.2.2	Etapa 2: Governança e Organização	47
3.2.3	Etapa 3: Enriquecimento semântico e estruturação do conhecimento com ontologias	48
3.2.4	Etapa 4: Modelagem	49
3.2.5	Etapa 5: Processamento com PLN e Geração de Informações	49
3.2.6	Etapa 6: Geração de Conteúdo e Retroalimentação da Plataforma	50
3.3	Considerações da metodologia	50
4	AValiação Experimental	53
4.1	A estrutura do protótipo	53
4.1.1	Entradas e Preparação dos Dados	53
4.1.2	Construção do Grafo de Conhecimento	54
4.1.3	Simulação do Banco de dados transacional	54
4.1.4	A cadeia de processamento com PLN	55
4.2	A validação: Casos de uso e evidências	55
4.2.1	Caso de uso 1: Relatório contábil consolidado	56

4.2.2	Caso de uso 2: Conexão faltante (Contábil vs. Vendas)	59
4.2.3	Caso de uso 3: Conexão faltante (Funcionário vs. Centro de custo)	60
4.2.4	Caso de uso 4: Uso de ontologia	62
4.2.5	Caso de uso 5: Governança de dados (Mascaramento de campo sensível) . .	65
4.2.6	Caso de uso 6: Conexões diretas de produto (Jornada completa)	66
4.2.7	Caso de uso 7: Meta-conhecimento (Relações da tabela produto)	70
4.2.8	Caso de uso 8: Meta-conhecimento (Relações da tabela produto com outras tabelas)	72
4.2.9	Caso de uso 9: Relatório completo de produto (Uso extenso da ontologia) .	74
4.3	Considerações do experimento	78
5	CONCLUSÕES E TRABALHOS FUTUROS	81
5.1	O desafio original e propósitos delineados	81
5.2	As conquistas e os aprendizados no caminho	81
5.3	Contribuições deste estudo	83
5.4	As limitações da abordagem	84
5.5	Trabalhos futuros	85
	REFERÊNCIAS	87

1 INTRODUÇÃO

A revolução digital transformou fundamentalmente a maneira como as organizações lidam com a informação. O que antes era limitado a arquivos físicos e bibliotecas corporativas hoje se expandiu para um universo digital de documentos, e-mails, mensagens instantâneas e bases de dados distribuídas. Esta explosão informacional, embora represente um potencial imenso de conhecimento, também evidencia um paradoxo organizacional contemporâneo: a abundância de informação nem sempre se traduz em conhecimento acionável ou em valor tangível para as instituições.

As organizações, sejam elas públicas, privadas ou do terceiro setor, enfrentam desafios significativos na gestão, organização e recuperação de suas informações. Estas dificuldades manifestam-se em diversos níveis: desde a impossibilidade de localizar documentos críticos rapidamente até a perda de conhecimento institucional quando colaboradores deixam a organização. O cenário se torna ainda mais complexo quando consideramos o volume crescente de dados não-estruturados como documentos textuais, relatórios técnicos e comunicações internas - que exigem abordagens sofisticadas para sua organização e recuperação efetiva.

A necessidade de abordar estes desafios informacionais torna-se cada vez mais urgente à medida que as organizações dependem crescentemente de seu capital intelectual. A motivação para esta pesquisa toma forma através da questão: **Como potencializar a circulação do conhecimento nas organizações**, cuja inquietação emerge da observação de que, apesar dos avanços tecnológicos, ainda existe uma lacuna significativa entre a disponibilidade de informação e sua efetiva utilização para geração de valor. A integração entre ciência da informação e inteligência artificial apresenta uma oportunidade única para preencher esta lacuna, justificando-se não apenas pela necessidade prática das organizações, mas também pela possibilidade de contribuir para o avanço teórico na intersecção destes campos. A modernidade tecnológica traz um grande espaço de oportunidades para exploração de abordagens que combinem efetivamente *frameworks* estabelecidos com tecnologias de Processamento de Linguagem Natural, tanto na literatura acadêmica quando no mercado profissional.

O objetivo central desta pesquisa foi investigar e propor uma abordagem que facilite essa potencialização através da absorção, circulação e o compartilhamento de conhecimento entre agentes humanos e máquinas (interagentes) bem como entre agentes humanos (intra-agentes), respeitando princípios fundamentais de governança, segurança e ética informacional, enquanto aborda todo o ciclo de transformação do conhecimento desde a socialização até a internalização, promovendo assim uma melhor eficiência entre as dimensões de tecnologia e negócios ou tecnologia e sociedade, dependendo

do cenário de implementação. Para fundamentar a pesquisa, foi concebida uma solução aplicando técnicas de *text-2-code*, onde foram coletadas informações do ambiente corporativo, essas informações foram catalogadas e organizadas dentro do ecossistema e na sequência disponibilizadas para que, através de linguagem natural, os consumidores fossem capazes de recuperar as informações desejadas utilizando-se de perguntas objetivas. Nesta abordagem buscou-se suporte em *frameworks* já estabelecidos no mercado, como *Data Management Body of Knowledge* e *Cross-Industry Standard Process for Data Mining* do lado de TI, os modelos *Open Data Product Specification* e o modelo Socialização, Externalização, Combinação, Internalização de gestão do conhecimento do lado de informação/negócios, tecnologias modernas de Processamento em Linguagem Natural como LangChain¹ e tecnologias computacionais como Neo4J², Sqlite³ e Python⁴, não se limitando aos respectivos.

Alguns cenários potenciais para a implementação da abordagem foram pensados como uma **Biblioteca Universitária**, onde um sistema poderia analisar publicações acadêmicas para identificar conexões temáticas. Em um **Departamento de Pesquisa e Desenvolvimento**, a abordagem poderia solucionar a fragmentação do conhecimento técnico e a dificuldade de localizar especialistas. Da mesma forma, em um **Centro de Documentação Público**, o sistema poderia tornar grandes volumes de documentos históricos mais acessíveis. Por fim, na **Gestão do Conhecimento Corporativo**, a abordagem pode manter e atualizar bases de conhecimento de forma eficiente ao integrar princípios do DAMA-DMBOK com o Processamento em Linguagem Natural para a organização documental.

Para a validação desta pesquisa, o cenário de **Gestão do Conhecimento Corporativo** foi o escolhido, dada a sua proximidade com minha experiência profissional e a viabilidade técnica para a validação. Os resultados experimentais, com base em casos de uso simulados, confirmaram a capacidade do sistema em construir consultas complexas e em identificar a ausência de conexões de dados. O protótipo desenvolvido demonstrou ser capaz de traduzir perguntas feitas em linguagem natural para consultas SQL, comprovando a viabilidade de utilizar grafos de conhecimento como um *proxy* inteligente, o que aumenta a segurança e a privacidade, pois apenas metadados e esquemas são expostos aos *Large Language Models*, e não os dados sensíveis.

Com base neste contexto, o presente trabalho se estrutura em cinco capítulos. O **Capítulo 2** aprofunda a fundamentação teórica, explorando conceitos essenciais de Ciência da Informação, Gestão do Conhecimento, Processamento em Linguagem Natural e os frameworks de governança e gestão que suportam a pesquisa, como o *Data Management*

¹ <https://www.langchain.com/langchain>

² <https://neo4j.com/product/auradb/>

³ <https://sqlite.org/>

⁴ <https://www.python.org/>

Body of Knowledge e o *Cross-Industry Standard Process for Data Mining*. No **Capítulo 3**, a metodologia de pesquisa é detalhada, explicando a abordagem aplicada e o desenvolvimento do protótipo, desde a captura do conhecimento até a modelagem com grafos e ontologias. O **Capítulo 4** apresenta a avaliação experimental do protótipo, discutindo os casos de uso simulados e analisando os resultados obtidos, incluindo a acurácia das consultas SQL geradas e a capacidade do sistema de raciocinar sobre metadados. Por fim, o **Capítulo 5** traz as conclusões do estudo, discutindo as contribuições, limitações e delineando os trabalhos futuros para aprimorar a abordagem proposta.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Ciência da Informação e Ecologia Informacional

A Ciência da Informação (CI) emerge como uma disciplina fundamental para compreender e gerenciar o complexo ecossistema informacional das organizações contemporâneas. A obra *Ecologia da Informação* Davenport (1998), propõe uma mudança paradigmática na forma como as organizações abordam a gestão informacional, distanciando-se de uma visão puramente tecnológica para adotar uma perspectiva holística que considera o ambiente informacional em sua totalidade.

Na perspectiva ecológica de Davenport, “a informação não pode ser dissociada do contexto humano em que ela existe e circula” Davenport (1998). O autor argumenta que, assim como um ecossistema natural, o ambiente informacional é constituído por diferentes elementos interdependentes: pessoas, processos, cultura organizacional, estruturas de poder e tecnologia. Esta abordagem ecológica reconhece que “a maneira como as pessoas criam, distribuem, compreendem e usam a informação” Davenport (1998) é tão ou mais importante que a própria tecnologia que suporta estes processos.

A ecologia informacional se estrutura em três ambientes:

- **Ambiente Informacional:** engloba a estratégia, política, comportamento, processos, arquitetura e equipe da informação
- **Ambiente Organizacional:** contempla a situação dos negócios, investimentos em tecnologia e estrutura física
- **Ambiente Externo:** incorpora os mercados de negócios, mercados de tecnologia e mercados de informação

2.2 Gestão do Conhecimento e Modelos de Transformação

O modelo SECI (Socialização, Externalização, Combinação, Internalização) Nonaka (2008), desenvolvido pelos pesquisadores japoneses Ikujiro Nonaka e Hirotaka Takeuchi, foi apresentado em 1995 através da obra *The Knowledge-Creating Company: How Japanese Companies Create the Dynamics of Innovation*. Este trabalho emergiu de um extenso estudo sobre as práticas de gestão japonesas, realizado na *Hitotsubashi University*, uma das mais prestigiadas instituições acadêmicas do Japão.

A contribuição de Nonaka e Takeuchi é particularmente significativa por ter sido um dos primeiros trabalhos acadêmicos a desafiar a visão ocidental predominante sobre gestão do conhecimento, que tradicionalmente enfatizava apenas o conhecimento explícito

e quantificável. Os autores, influenciados pela tradição filosófica oriental e pela observação detalhada de empresas japonesas como Toyota, Honda e Canon, trouxeram à tona a importância do conhecimento tácito nas organizações.

O modelo SECI representa a espiral do conhecimento, um processo dinâmico onde o conhecimento organizacional é criado através da interação contínua entre conhecimento tácito e explícito:

- **Socialização (de tácito para tácito):**
 - Processo de compartilhamento de experiências
 - Ocorre através da observação, imitação e prática
 - Exemplificado em práticas como mentoria e aprendizado *on-the-job*
- **Externalização (de tácito para explícito):**
 - Articulação do conhecimento tácito em conceitos explícitos
 - Frequentemente mediada por metáforas, analogias e modelos
 - Considerada pelos autores como a chave para a criação do conhecimento
- **Combinação (de explícito para explícito):**
 - Sistematização de conceitos em um sistema de conhecimento
 - Envolve a combinação de diferentes corpos de conhecimento explícito
 - Materializada em documentos, bancos de dados e sistemas de informação
- **Internalização (de explícito para tácito):**
 - Incorporação do conhecimento explícito em conhecimento tácito
 - Relacionada ao "aprender fazendo"
 - Resulta na criação de modelos mentais e know-how técnico

Este modelo é particularmente relevante quando consideramos a integração com tecnologias de PLN (Processamento em Linguagem Natural), pois estas podem atuar como facilitadoras em diferentes etapas do ciclo SECI, especialmente nos processos de externalização e combinação do conhecimento. Cada um destes processos de conversão do conhecimento apresenta desafios específicos que podem ser endereçados através da integração entre CI e tecnologias de IA (Inteligência Artificial). A externalização, por exemplo, pode ser potencializada por ferramentas de PLN que auxiliam na captura e estruturação do conhecimento tácito, enquanto a combinação pode ser otimizada por sistemas que identificam padrões e relacionamentos entre diferentes corpos de conhecimento explícito.

2.3 Arquitetura e Contextos de Informação

O DDD (*Domain-Driven Design*), proposto por Evans (2016), emerge como uma abordagem fundamental para estruturar sistemas complexos de informação e conhecimento. Embora originalmente concebido para o desenvolvimento de *software*, seus princípios se mostram particularmente valiosos na integração entre CI e PLN. Evans (2016) introduz o conceito de *Bounded Contexts* (Contextos Delimitados), que oferece um *framework* poderoso para organizar e gerenciar diferentes domínios de conhecimento dentro de uma organização. Este conceito é especialmente relevante quando consideramos a natureza heterogênea do conhecimento organizacional e a necessidade de estabelecer fronteiras claras entre diferentes contextos informacionais. Também temos a *Ubiquitous Language* (Linguagem Ubíqua), outro conceito central do DDD, estabelece uma ponte natural entre os especialistas do domínio e os sistemas de processamento de linguagem natural. Evans enfatiza que esta linguagem comum deve emergir através de um processo iterativo de colaboração entre todos os stakeholders, criando um vocabulário compartilhado que pode ser igualmente compreendido por humanos e máquinas (Evans, 2016).

2.4 Processamento em Linguagem Natural

O PLN representa um conjunto de técnicas computacionais para análise e geração automática de língua natural Caseli e Nunes (2024). “Com PLN buscam-se soluções para problemas computacionais, ou seja, tarefas, sistemas, aplicações ou programas, que requerem o tratamento computacional de uma língua (português, inglês etc.), seja escrita (texto) ou falada (fala). Línguas como as de sinais também têm sido alvo de estudos da área. Cada modo tem suas especificidades” Caseli e Nunes (2024). No contexto da gestão do conhecimento organizacional, o PLN atua como uma ponte tecnológica fundamental, permitindo a transformação de conhecimento não-estruturado em formatos mais facilmente gerenciáveis e recuperáveis.

O processamento do texto em PLN começa com a análise da estrutura linguística em diferentes níveis, alinhando-se naturalmente com as necessidades de processamento do conhecimento organizacional. A análise se dá nos seguintes níveis:

- **Nível Morfológico:** Análise da estrutura e formação das palavras. Em PLN, a unidade de processamento mais comum é o *token*, “definido como qualquer sequência de caracteres à qual se atribui um valor” Caseli e Nunes (2024). Em algumas línguas, como o português, um *token* é frequentemente a palavra escrita. Para sistemas modernos baseados em redes neurais, a **tokenização em subpalavras** (*subword*) tornou-se popular, buscando quebrar palavras em porções menores para reduzir o vocabulário de trabalho do modelo a um tamanho finito.

- **Nível Sintático:** Estudo da organização das palavras em sentenças. A sintaxe é uma camada central no sistema linguístico, pois organiza as funções da morfologia e fornece estruturas essenciais para as camadas superiores (semântica e pragmática). A análise computacional nesse nível é denominada *parsing*, sendo a **sintaxe de dependência** o tipo de *parsing* mais utilizado atualmente.
- **Nível Semântico:** Compreensão do significado das palavras e sentenças. Após a análise estrutural, o PLN se dedica a tarefas de **Extração de Informação (EI)** Liu *et al.* (2024), que transforma dados textuais não-estruturados em dados estruturados. A EI tradicional inclui duas tarefas primárias: o **Reconhecimento de Entidades Nomeadas (REN)** Li *et al.* (2018), que identifica fragmentos de texto que se referem a entidades como Pessoas ou Locais e a **Extração de Relações (ER)** Zhao *et al.* (2024), que identifica os relacionamentos entre essas entidades. Uma abordagem mais moderna é a Extração Conjunta de Entidades e Relações.
- **Nível Pragmático:** Aplicação da linguagem em contextos específicos. A **Complexidade Textual e a Simplificação Textual (ST)** são temas diretamente ligados a esse nível, buscando adaptar textos para facilitar a compreensão. A ST pode ocorrer por meio da Elaboração Textual, que adiciona informações como sinônimos ou definições curtas.

A ascensão dos modelos neurais transformou o campo. Os **LLMs** Minaee *et al.* (2025), tipicamente com mais de um bilhão de parâmetros, são classificados como métodos de **IA Generativa**, cuja função primária é a geração de conteúdo. Eles demonstram habilidades como o aprendizado em contexto (*in-context learning*), permitindo que sejam utilizados por meio de instruções em linguagem natural. No entanto, uma limitação significativa é que esses modelos aprendem a reproduzir padrões de coocorrência e contexto nos dados de treinamento, e não a língua em si, o que pode resultar em "alucinações". LLMs gerativos são utilizados em **agentes de conversação** Allouch, Azaria e Azoulay-Schwartz (2021), como *chatbots*, sendo eficazes em encadear palavras de modo coerente, com base em previsões e probabilidade. **Os sistemas de Perguntas e Respostas**, por sua vez, são desenvolvidos para processar uma pergunta e definir a resposta, utilizando alguma forma de base de conhecimento. A fonte de conhecimento pode ser composta por dados não-estruturados ou por dados estruturados, como um **grafo de conhecimento**.

Por fim, a **avaliação** é um passo essencial no desenvolvimento de sistemas de PLN, pois mede a performance e garante a qualidade e a ética. É vital analisar os dados usados no treinamento, pois os modelos podem captar vieses sociais ou artefatos de anotação. Para o desenvolvimento responsável dessas tecnologias, a avaliação deve ser rigorosa, com foco na interpretabilidade e no diagnóstico dos modelos. Adicionalmente, os profissionais

devem ter cautela ao relatar resultados, evitando verbos e conceitos que antropomorfizam os sistemas, como "entender" ou "pensar".

Os conceitos de tokenização, EI, REN, ER, LLMs e agentes de conversação foram utilizados na metodologia, através do uso de serviços de IA generativa e de bibliotecas específicas implementadas através da linguagem python.

2.5 Grafos de Conhecimento

2.5.1 Definição e Propósito

Grafos de conhecimento são estruturas de dados que representam informações como um grafo, onde nós representam entidades (conceitos, objetos, eventos) e arestas representam as relações entre elas. Essa abordagem permite modelar o conhecimento de forma que as relações e o contexto sejam tão importantes quanto os dados em si, possibilitando inferências e descobertas que seriam difíceis com abordagens tradicionais. A figura 1¹ mostra um exemplo de um grafo simples.




Figura 1 – Grafo de conhecimento (Fonte: Neo4J)

Como apontado por Guizzardi Giancarlo e Guarino (2024) “sempre que temos algo importante, mas difícil de entender, devemos concentrar nossa atenção em encontrar quais são as entidades primárias no domínio sob investigação. Descobrir essas entidades e suas propriedades intrínsecas e estruturais, em vez de manipular símbolos matemáticos não interpretados ou mal interpretados, ou especular sobre leis e princípios universais de livre flutuação, é o verdadeiro trabalho da ciência. Formalismos matemáticos, leis e princípios universais são relevantes e importantes apenas quando têm uma base ontológica firme”.

¹ Disponível em: <https://neo4j.com/docs/getting-started/cypher/>

A ideia de representar conhecimento em grafos tem raízes na teoria dos grafos e na semântica da web. O termo ganhou popularidade com o *Google Knowledge Graph*² em 2012, que demonstrou o poder de um grafo de conhecimento em larga escala para aprimorar resultados de busca. Desde então, a pesquisa e o desenvolvimento em grafos de conhecimento têm crescido exponencialmente. Grafos de conhecimento são utilizados em diversas áreas, como em busca semântica, para aprimorar a precisão e relevância dos resultados de busca; em sistemas de recomendação, para personalizar recomendações com base em conexões e preferências; na análise de redes sociais, para identificar padrões e influenciadores em redes complexas; na gestão do conhecimento, para organizar e facilitar o acesso ao conhecimento corporativo; e em IA, fornecendo uma base de conhecimento estruturado para sistemas inteligentes.

Os desafios incluem escalabilidade, qualidade dos dados e interoperabilidade. As perspectivas futuras envolvem aprendizado de máquina em grafos, grafos distribuídos e multimodais, e a construção automática de grafos a partir de dados não estruturados.

2.6 Ontologias e Representação do Conhecimento

A palavra Ontologia é implementada de diferentes maneiras em várias áreas do conhecimento. Citando duas das principais, a primeira tem sua origem na filosofia, tratando-se do ramo que “trata da natureza e estrutura da realidade. Aristóteles tratou deste assunto na sua metafísica e definiu ontologia como a ciência do “ser enquanto ser”, ou seja, o estudo dos atributos que pertencem às coisas devido à sua própria natureza” (S.; Studer, 2009). Já no segundo caso, relaciona-se a ciência da computação, refere-se como “um tipo especial de objeto de informação ou artefato computacional. A explicação da existência neste caso é pragmática: Para sistemas de IA, o que ‘existe’ é aquilo que pode ser representado” (S.; Studer, 2009). Na figura 2³ temos um exemplo mostrando uma ontologia de uma empresa, seus funcionários, consultores e os projetos em que estão trabalhando.

As ontologias, no contexto da Ciência da Computação e CI, emergiram como um componente fundamental para a representação formal do conhecimento. Originadas nos trabalhos do *Stanford Knowledge Systems Laboratory*⁴ nos anos 1980, as ontologias evoluíram de conceitos filosóficos para ferramentas práticas de organização e estruturação do conhecimento em sistemas computacionais.

Na interseção entre Ciência da Informação e Processamento de Linguagem Natural, as ontologias desempenham três papéis cruciais:

- **Estruturação do Conhecimento**

² Disponível em: <https://support.google.com/knowledgepanel/answer/9787176?hl=en>

³ Figuras em resolução ampliada disponíveis em: <https://enterprise-knowledge.com/what-is-an-ontology>

⁴ Disponível em: <http://www-ksl.stanford.edu/>




Figura 2 – Representação de uma Ontologia (Fonte: Enterprise Knowledge)

- Definição formal de conceitos e suas relações
- Estabelecimento de hierarquias conceituais
- Padronização de vocabulários controlados
- Mapeamento de relações semânticas

• Suporte ao PLN

- Fornecimento de contexto semântico para análise textual
- Desambiguação de termos e conceitos
- Enriquecimento de análises linguísticas
- Melhoria na precisão de sistemas de recuperação de informação

• Integração de Sistemas

- Facilitação da interoperabilidade semântica
- Padronização de vocabulários entre sistemas
- Mapeamento entre diferentes domínios de conhecimento
- Suporte à tradução e conversão entre formatos

O *World Wide Web Consortium*⁵ estabeleceu padrões fundamentais para a implementação de ontologias, incluindo:

⁵ Disponível em: <https://www.w3.org/>

- RDF (*Resource Description framework*)⁶
- OWL (*Web Ontology Language*)⁷
- SPARQL (Protocolo e linguagem de consulta)⁸

Trazendo as ideias de Guizzardi Giancarlo e Guarino (2024), “os termos semântica e ontologia estão cada vez mais aparecendo junto com explicação, não apenas na literatura científica, mas também nas interações sociais cotidianas, em particular, dentro das organizações. Ontologias têm demonstrado desempenhar um papel fundamental no suporte à interoperabilidade semântica de estruturas de representação de dados e conhecimento usadas por sistemas de informação. Com a proliferação de aplicações de Inteligência Artificial (IA) em diferentes cenários e a crescente necessidade de garantir sua explicabilidade (mas também sua interoperabilidade) em contextos críticos, o termo explicação também se tornou parte do jargão científico e técnico da engenharia moderna de sistemas de informação. No entanto, todos esses termos também são significativamente sobrecarregados”.

No contexto organizacional, as ontologias atuam como pontes entre o conhecimento humano estruturado e os sistemas de processamento automático, permitindo uma integração mais efetiva entre práticas tradicionais de gestão do conhecimento e tecnologias modernas de PLN.

2.7 Frameworks de Governança e Gestão de informação

2.7.1 DAMA-DMBOK e a DAMA *International*

O *Data Management Body of Knowledge* (DAMA-DMBOK) (DAMA, 2017) é mantido e desenvolvido pela DAMA *International* (*Data Management Association*), uma organização profissional global sem fins lucrativos fundada em 1980. A DAMA *International* é reconhecida como a principal autoridade em gestão de dados, reunindo vários *chapters* em todo o mundo e estabelecendo padrões profissionais para a prática de gestão de dados.

A associação surgiu da necessidade de estabelecer padrões profissionais em um momento em que a gestão de dados emergia como disciplina crítica nas organizações. O DAMA (2017), agora em sua segunda versão, representa a consolidação de décadas de experiência prática e pesquisa acadêmica, fornecendo um *framework* que é tanto rigoroso quanto aplicável. O *framework* estabelece áreas de conhecimento essenciais conforme mostrado na figura 3 a seguir:

⁶ Disponível em: <https://www.w3.org/RDF/>

⁷ Disponível em: <https://www.w3.org/TR/owl-features/>

⁸ Disponível em: <https://www.w3.org/TR/rdf-sparql-query/>




Figura 3 – Mandala de competências do DMBOK (Fonte: DMBOK)

2.7.2 CRISP-DM e seu Consórcio Original

O *Cross-Industry Standard Process for Data Mining* (CRISP-DM) foi originalmente desenvolvido por um consórcio de empresas europeias em 1996, liderado por SPSS (agora parte da IBM), NCR *Corporation* e DaimlerChrysler. O projeto foi parcialmente financiado pela Comissão Europeia no âmbito do programa ESPRIT (*European Strategic Programme for Research in Information Technology*) para o desenvolvimento de padrões da indústria europeia de TI.

Segundo guia da IBM⁹. “CRISP-DM, que significa Processo Padrão de Vários Segmentos de Mercados para Mineração de Dados, é uma forma comprovada pelo mercado para orientar seus esforços de mineração de dados. Como uma metodologia, ela inclui descrições das fases típicas de um projeto, as tarefas envolvidas em cada fase e uma explicação dos relacionamentos entre essas tarefas. Como um modelo de processo, o CRISP-DM fornece uma visão geral do ciclo de vida da mineração de dados.”

O que torna o CRISP-DM particularmente interessante para o contexto acadêmico é sua origem como um esforço colaborativo entre indústria e academia. Embora tenha surgido do setor privado, o *framework* foi desenvolvido com forte embasamento metodológico e validação científica, sendo objeto de numerosas publicações acadêmicas desde sua criação. A metodologia propõe seis fases interativas e cíclicas conforme mostrado na figura 4:

Embora o CRISP-DM tenha sido inicialmente concebido para mineração de dados tradicional, sua estrutura metodológica tem se mostrado igualmente valiosa para projetos de PLN e IA em geral, devido à sua ênfase em compreensão contextual e avaliação rigorosa.

2.7.3 Open Data Product Specification (ODPS)

O *Open Data Product Specification* Moilanen e Sorg (2024) foi originalmente concebido e desenvolvido pelo Dr. Jarkko Moilanen e Jussi Niilahti antes de sua incorporação à *Linux Foundation*. O projeto nasceu da necessidade de estabelecer padrões abertos para a descrição e gerenciamento de produtos de dados, em um momento em que a economia de dados demandava maior padronização e interoperabilidade. Em sua versão 3.1, ODPS estabelece um modelo de metadados neutro em relação a fornecedores e de código aberto, desenvolvido especificamente para descrever produtos de dados digitais.

O *framework* se fundamenta em quatro dimensões principais de produtos de dados:

- **Técnica**
 - Infraestrutura e acesso
 - Aspectos arquiteturais

⁹ Disponível em: https://www.ibm.com/docs/pt-br/SS3RA7_18.5.0/nl/pt/BR/pdf/ModelerCRISPDM.pdf




Figura 4 – O ciclo de vida da mineração de dados (Fonte: IBM)

– Padrões de implementação

- **Negócios**

- Modelos de precificação
- Planos de comercialização
- Métricas de valor

- **Legal**

- Licenciamento
- Propriedade intelectual

- Conformidade regulatória

- **Ética**

- Privacidade
- Aspectos de *MyData* (para mais informações, checar referência bibliográfica)
- Governança de dados

O ODPS implementa estas dimensões através de sete objetos principais:

- **Atributos em Nível de Documento (*Document Level Attributes*)**

- Definição de metadados básicos
- Versionamento
- Identificação unívoca do produto

- **SLA de Dados (*Data Service Level Agreement*)**

- 11 dimensões padronizadas para acordos de nível de serviço
- Monitoramento desacoplado através de *Everything as Code*
- Métricas de disponibilidade e performance

- **Qualidade de Dados (*Data Quality*)**

- 8 opções padronizadas para definição e medição
- *framework* de monitoramento integrado
- Indicadores de conformidade

- **Planos de Precificação (*Data Pricing Plans*)**

- Suporte a 12 modelos de precificação padronizados
- Flexibilidade para customização
- Gestão de ciclo de vida do produto

- **Licenciamento (*Data Licensing*)**

- Estrutura para definição de termos de uso
- Gestão de direitos e restrições
- Conformidade legal

- **DataOps**

- Automação de processos

- Gestão de *pipeline* de dados
- Práticas DevOps aplicadas a dados
- **Acesso aos Dados (Data Access)**
 - Protocolos de acesso
 - Controles de segurança
 - APIs e interfaces

O ODPS se diferencia de outras especificações por sua abordagem *Everything as Code*, que permite a automação e o monitoramento programático de aspectos como SLA, qualidade de dados e precificação. Esta característica facilita a integração com ferramentas modernas de DataOps e plataformas de dados.

A especificação utiliza YAML¹⁰ (*Yet another markup Language*) como formato principal para sua implementação, facilitando tanto a leitura humana quanto o processamento por máquina. O ODPS também incorpora conceitos de *Data Mesh*, permitindo que produtos de dados sejam tratados como entidades independentes, desacopladas de sistemas específicos de marketplace ou catálogo.

2.8 Considerações Finais

Este capítulo estabeleceu as bases teóricas para a integração entre Ciência da Informação e PLN, visando otimizar o compartilhamento de conhecimento organizacional. Iniciamos com a Ciência da Informação e a Ecologia Informacional, destacando a importância de compreender e gerenciar o ecossistema informacional das organizações. Em seguida, abordamos a Gestão do Conhecimento e os Modelos de Transformação, com foco no modelo SECI descrevendo a espiral do conhecimento como um processo dinâmico de interação entre conhecimento tácito e explícito, crucial para a inovação e o aprendizado organizacional. A Arquitetura e os Contextos de Informação, influenciados pelo DDD como elementos-chave para estruturar sistemas complexos de informação e conhecimento. O PLN, foi explorado como um conjunto de técnicas computacionais para análise e geração de língua natural, com potencial para transformar conhecimento não estruturado em formatos gerenciáveis. Os Grafos de Conhecimento como ferramentas para aprimorar a busca semântica, os sistemas de recomendação e a gestão do conhecimento. As Ontologias como componentes fundamentais para representação formal do conhecimento, permitindo a estruturação, padronização e a integração de sistemas. Por fim, exploramos os *frameworks* de Governança e Gestão da Informação, como DAMA-DMBOK, CRISP-DM e ODPS, que fornecem uma base metodológica para a implementação da proposta.

¹⁰ Disponível em: <https://yaml.org/>

É fundamental ressaltar que, embora *frameworks* como o CRISP-DM e o ODPS representem abordagens ideais e robustas para projetos de ciência de dados e especificação de produtos de dados, respectivamente, a natureza do protótipo desenvolvido no presente estudo, focado em uma prova de conceito de viabilidade, levou a adaptações em sua aplicação operacional. O CRISP-DM, por exemplo, serviu como um guia conceitual para as fases do projeto, mas não foi seguido de forma rígida em todas as suas iterações, dada a agilidade necessária. De forma análoga, a especificação detalhada de produtos de dados via ODPS em formato YAML, embora reconhecida por sua relevância para a interoperabilidade e automação, não foi implementada diretamente no protótipo. Em vez disso, a representação formal do conhecimento no grafo de conhecimento foi priorizada, utilizando padrões da Web Semântica como RDF e OWL, que se alinham diretamente aos objetivos de enriquecimento semântico e estruturação do conhecimento para o PLN, conforme detalhado no Capítulo 3. Tais escolhas metodológicas serão explicitadas para garantir a coerência entre o referencial teórico e a materialização da proposta.

Com base neste referencial teórico, o próximo capítulo apresentará a proposta metodológica, detalhando os métodos de coleta e análise de dados, os critérios de seleção do cenário de implementação e os indicadores de avaliação dos resultados. A proposta metodológica buscará integrar os *frameworks* apresentados, aplicando os princípios da Ciência da Informação e as técnicas de PLN de forma coerente e consistente.

3 METODOLOGIA

3.1 Abordagem Metodológica

A metodologia adotada nesta pesquisa tem como objetivo principal demonstrar como a integração entre CI e PLN pode otimizar o ciclo de vida da informação na gestão do conhecimento corporativo. Adicionalmente, busca-se evidenciar como a organização eficaz da informação contribui para a acurácia das respostas de modelos de PLN. A abordagem metodológica enfatiza a importância da combinação de *frameworks* e tecnologias existentes, em vez do desenvolvimento de novas soluções. Para alcançar esses objetivos, a pesquisa adota uma abordagem aplicada, buscando desenvolver uma solução prática para um problema real das organizações. A solução foi desenvolvida por meio da integração de fundamentos teóricos, como o modelo SECI e da inspiração em *frameworks* de gestão (DAMA-DMBOK, CRISP-DM, ODPS) em um modelo único que orientou o processo de captura, organização, processamento e utilização da informação. A avaliação da solução foi realizada por meio da análise qualitativa e quantitativa dos resultados da aplicação do modelo em um cenário de gestão do conhecimento corporativo. A implementação da solução envolveu o uso de tecnologias como *LangChain* (Python) para PLN e bancos de dados para armazenamento da informação. Os *frameworks* DAMA-DMBOK, CRISP-DM e o modelo SECI foram utilizados como guias metodológicos e conceituais, fornecendo a estrutura e os princípios para o desenvolvimento da solução.

As Figuras 5 e 6¹ apresentam um diagrama de blocos do pipeline do processo, ilustrando as principais etapas da metodologia. Cada etapa será detalhada nas seções subsequentes, descrevendo como os dados de entrada são transformados até a produção da saída esperada.

3.2 Proposta de Desenvolvimento

3.2.1 Etapa 1: Captura de Dados e Conhecimento

A primeira etapa da metodologia envolveu a captura de dados operacionais e a explicitação do conhecimento tácito presente na organização. Os dados operacionais foram extraídos dos sistemas transacionais da empresa. Para os propósitos deste estudo, o conhecimento tácito, que geralmente é compartilhado por meio de diferentes fontes como reuniões, wikis (por exemplo, Confluence²) e podcasts, foi considerado já transformado em artefatos explícitos de entrada para o protótipo. Esta etapa corresponde à fase de **Socialização** do modelo SECI, conforme mostrado na figura 7 (detalhamento na seção

¹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SkPL>

² Disponível em: <https://www.atlassian.com/software/confluence>

2.2), onde o conhecimento é compartilhado entre os indivíduos, facilitando a criação de conhecimento tácito por meio da interação social e servindo de base para a formação de conhecimento explícito.




Figura 7 – Socialização e captura de conhecimento tácito (Fonte: Autor)

3.2.2 Etapa 2: Governança e Organização

Após a captura, os dados e o conhecimento foram submetidos a um processo de governança e organização. Para os fins deste estudo, esta etapa concentrou-se na estruturação e na injeção de metadados, utilizando o *framework* DAMA-DMBOK como guia conceitual. Isso incluiu a organização e o mapeamento de informações sobre qualidade de dados, modelagem, metadados e gerenciamento de conteúdo, visando estruturar a informação para facilitar o processamento e a recuperação. Esta etapa está relacionada à fase de **Externalização** do modelo SECI, conforme ilustrado na figura 8 (detalhamento na seção 2.2), onde o conhecimento tácito é convertido em conhecimento explícito, tornando-o mais acessível e utilizável.




Figura 8 – Externalização do conhecimento (Fonte: Autor)

3.2.3 Etapa 3: Enriquecimento semântico e estruturação do conhecimento com ontologias

Para garantir a representação formal e a interoperabilidade do conhecimento para consumo por sistemas de IA, esta etapa concentrou-se no enriquecimento semântico. Embora a ODPS seja reconhecida como um *framework* ideal para a padronização e gerenciamento de produtos de dados, sua aplicação operacional em formato YAML não foi adotada neste protótipo devido a restrições de escopo e tempo. Em vez disso, a especificação e formalização do conhecimento foram realizadas por meio da construção e utilização de ontologias, expressas em padrões da Web Semântica como OWL e RDF. Essas ontologias permitiram definir formalmente conceitos, propriedades e relações do domínio de negócio, fornecendo uma base estruturada e semanticamente rica para a IA. Esta etapa contribui diretamente para a fase de **Combinação** do modelo SECI, onde diferentes formas de conhecimento explícito são integradas e estruturadas em um sistema de conhecimento mais amplo e coerente.

3.2.4 Etapa 4: Modelagem

Nesta etapa, os dados e o conhecimento foram modelados utilizando grafos de conhecimento e ontologias, conforme ilustrado na figura 9³. Os grafos podem ser gerados tanto a partir dos dados estruturados da empresa (e.g., modelo lógico da plataforma de dados) quanto a partir do processamento de documentos não estruturados pelo PLN (e.g., grafo de temas de podcasts). As ontologias fornecem uma estrutura semântica para o conhecimento, permitindo a inferência e a descoberta de novos conhecimentos. Os grafos gerados foram fornecidos aos motores de PLN para enriquecer o contexto e melhorar a compreensão das relações entre as informações. Esta etapa aprofunda a fase de **Combinação** do modelo SECI, refinando a estrutura do conhecimento e preparando-o para a interação com as IAs.




Figura 9 – Grafo de conhecimento (Fonte: Autor)

3.2.5 Etapa 5: Processamento com PLN e Geração de Informações

Os dados e o conhecimento organizados, especificados e modelados foram então disponibilizados para os usuários por meio da plataforma de dados, permitindo o consumo *self-service*. Os usuários interagiram com os motores de PLN, implementados com a biblioteca *LangChain* em Python, para extrair novos conhecimentos e *insights* da plataforma. As técnicas de PLN foram utilizadas para responder a perguntas, gerar resumos, identificar tendências e realizar outras análises. Esta etapa conecta as fases de **Combinação** e

³ Figuras em resolução ampliada disponíveis em: <https://shre.in/SkPg>

Internalização do modelo SECI, conforme ilustrado na figura 10 (detalhamento na seção 2.2), onde o conhecimento é sistematizado, compartilhado e incorporado pelos usuários.




Figura 10 – Combinação e Internalização do conhecimento (Fonte: Autor)

3.2.6 Etapa 6: Geração de Conteúdo e Retroalimentação da Plataforma

Nesta última etapa, a solução se direcionou para a produção de conhecimento e conteúdo. Os usuários interagiram com a plataforma, utilizando os motores de PLN para explorar os dados e informações disponíveis e gerar novos insights. As técnicas de PLN foram aplicadas para facilitar a criação de diferentes formatos de conteúdo, como relatórios, resumos, artigos, apresentações e respostas a perguntas complexas.

Além disso, a plataforma seria retroalimentada com os *prompts* e artefatos gerados durante o processo de produção de conteúdo. Essa retroalimentação contínua enriquece a base de conhecimento da plataforma, aprimora a qualidade e a relevância do conteúdo gerado pelo PLN e contribui para a aprendizagem organizacional. Devido a restrição de escopo e tempo, esta etapa não foi implementada, ficando em aberto para trabalhos futuros. Os dados e informações bem estruturados se transformam em ativos de conteúdo valiosos, que podem ser utilizados para diversas finalidades, como comunicação interna, treinamento, marketing e suporte à decisão.

3.3 Considerações da metodologia

Neste capítulo, detalhamos a metodologia proposta para integrar CI e PLN, visando otimizar a gestão do conhecimento corporativo. Apresentou-se um modelo que combina fundamentos teóricos e práticos, guiado pelo ciclo SECI, para capturar, organizar,

formalizar semanticamente, modelar, processar e utilizar o conhecimento organizacional. As etapas descritas estabeleceram um fluxo de trabalho coeso, desde a extração de dados e conhecimento até a produção de conteúdo valioso para a tomada de decisão.

O próximo capítulo apresentará os resultados da aplicação dessa metodologia em um cenário de gestão do conhecimento corporativo. Serão analisados os benefícios da integração entre Ciência da Informação e PLN, bem como o impacto da organização da informação na qualidade do conteúdo gerado.

4 AVALIAÇÃO EXPERIMENTAL

4.1 A estrutura do protótipo

O protótipo foi concebido como uma arquitetura modular, interligando diferentes tecnologias para simular o fluxo de conhecimento em um ambiente corporativo. A espinha dorsal dessa estrutura é o grafo de conhecimento **Neo4j**, que centraliza metadados e relações semânticas, agindo como a camada de inteligência para os modelos de PLN. O banco de dados **SQLite** foi utilizado para simular um sistema transacional ou *data warehouse*, sendo o alvo das consultas **SQL** geradas. A orquestração das interações e o raciocínio do LLM foram gerenciados pela biblioteca **LangChain**, com o uso de *embeddings* para a busca de similaridade semântica. A figura 11 representa o desenho desta solução e a interligação entre os componentes, mostrando desde a transformação das informações capturadas (metadados, termos de negócio e modelo lógico), a geração dos *embeddings*, grafos e conexão com as pergunta dos usuários.




Figura 11 – Desenho de solução de componentes (Fonte: Autor)

4.1.1 Entradas e Preparação dos Dados

O processo iniciou com o carregamento de artefatos de conhecimento, que representam o resultado da externalização do conhecimento de domínio:

- **Modelo Lógico Expandido:** Um arquivo CSV (modelo lógico) contendo a estrutura de tabelas, colunas, tipos de dados e relacionamentos de chave primária/estrangeira de um domínio de negócio simulado.

- **Metadados de Governança:** Um arquivo CSV (catálogo) com metadados adicionais, como classificação de confidencialidade, proprietário dos dados e regras de qualidade, alinhados a princípios de governança de dados como o DAMA-DMBOK.
- **Ontologia do Domínio:** Um arquivo TTL (ontologia dos termos de negócio) que define formalmente os conceitos, propriedades e relações semânticas do domínio de negócio, utilizando os padrões OWL/RDF.

4.1.2 Construção do Grafo de Conhecimento

Estes dados foram injetados no Neo4j, formando o grafo de conhecimento, conforme figura 12¹. Cada tabela, coluna, conceito e propriedade da ontologia é representada como um nó no grafo. Crucialmente, *embeddings* vetoriais são calculados para cada um desses nós utilizando o modelo `sentence-transformers/paraphrase-MiniLM-L6-v2`, a partir de suas descrições textuais e contextuais. Esses *embeddings* são armazenados como propriedades dos nós, habilitando a busca semântica. Relacionamentos entre tabelas (via chaves estrangeiras), entre tabelas e suas colunas e entre conceitos e propriedades da ontologia são criados, enriquecendo a estrutura do grafo.




Figura 12 – Trecho do grafo com os principais componentes (Fonte: Autor)

4.1.3 Simulação do Banco de dados transacional

Um banco de dados SQLite foi criado e populado com dados de exemplo, espelhando o modelo lógico e os metadados. Este banco serviu como a fonte de dados real sobre a

¹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQm6>

qual as consultas SQL geradas serão executadas, validando a funcionalidade do sistema em um ambiente de dados transacional.

4.1.4 A cadeia de processamento com PLN

A interação central do protótipo ocorreu através de uma cadeia LangChain. Essa cadeia é responsável por:

- Receber a pergunta do usuário em linguagem natural.
- **Realizar busca semântica no grafo de conhecimento:** A pergunta do usuário foi convertida em um *embedding*. Esse *embedding* é comparado com os *embeddings* de todos os nós relevantes no Neo4j (tabelas, colunas, conceitos, propriedades) para identificar os elementos mais semanticamente próximos à intenção do usuário.
- **Fornecer contexto ao LLM:** Os elementos relevantes recuperados do grafo, juntamente com o esquema completo do banco de dados SQLite, foram formatados em um *prompt* detalhado e direcionado ao LLM.
- **Geração de SQL e Explicação:** O LLM (foi usado {Google Gemini 1.5 Flash Latest}), utilizando o contexto fornecido, gerou a consulta SQL mais adequada para a pergunta e uma explicação clara da lógica por trás dessa consulta. A escolha do modelo foi definida com base em critérios como tamanho (o projeto foi executado no google colab) e gratuidade dos tokens.
- **Execução da SQL:** A query SQL gerada foi então executada no banco de dados SQLite simulado.

A imagem mostrada no início da subseção mostra o fluxo explicado até aqui.

4.2 A validação: Casos de uso e evidências

Para demonstrar a capacidade da abordagem proposta, foi realizada uma avaliação experimental com base em casos de uso simulados, representativos de perguntas que poderiam ser feitas por usuários de negócio em um ambiente corporativo. A validação teve um caráter de prova de conceito funcional, focando na capacidade do sistema em traduzir corretamente a intenção do usuário em consultas SQL acionáveis.

A metodologia de validação empregou a comparação entre os resultados das consultas geradas pelo LLM e as *queries* SQL de gabarito (*golden queries*), previamente definidas por especialistas. Para cada caso de uso avaliado, a *query* gerada pelo LLM foi executada no banco de dados SQLite simulado. Em paralelo, a *query* de gabarito correspondente foi executada. A acurácia de resultados foi a métrica primária, onde a correspondência dos

conjuntos de dados retornados pela *query* do LLM com os da *query* de gabarito determinou a correção funcional da resposta. Este processo permitiu uma verificação objetiva e prática da eficácia do sistema em gerar SQL semântica e sintaticamente correto para o domínio em questão. O *notebook* **PoC_Golden_Queries**² foi utilizado para a execução e comparação dessas queries de validação.

A seguir, apresentam-se os casos de uso selecionados, ilustrando o fluxo da pergunta à resposta e discutindo os resultados obtidos:

4.2.1 Caso de uso 1: Relatório contábil consolidado

- **Pergunta do Usuário:** “Gere um relatório que mostre os lançamentos contábeis, incluindo a data, o valor, o tipo, o nome da conta contábil e o centro de custo associado. Inclua todas as colunas dessas tabelas.”
- **Discussão:** Este cenário visa testar a capacidade do sistema em realizar múltiplos *JOINS* complexos entre tabelas relacionadas a diferentes aspectos financeiros (lançamentos, contas contábeis, centros de custo). A pergunta exige uma compreensão das conexões entre os nós `Lancamento_Contabil`, `Lancamento_Contabil_CC`, `Centro_Custo`, e `Conta_Contabil`.
- **Elementos Relevantes do Grafo:** Figura 13³

```

=== Teste Caso de Uso 1: Relatório Contábil (4 Joins) ===

Pergunta: Gere um relatório que mostre os lançamentos contábeis, incluindo a data, o valor, o tipo, o nome da conta contábil e o centro de custo associado. Inclua todas as colunas dessas tabelas.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [0.05918455123981367, -0.08591415733098984, -0.1928202509880066, -0.1681868396607834, -0.3114309310913086]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: Quantidade_Disponivel, Labels: ['column'], Domínio: Cadeia Logística, Similaridade: 0.6741
- Nome: ID_Conta_Contabil, Labels: ['column'], Domínio: Financas, Similaridade: 0.6691
- Nome: ID_Centro_Custo, Labels: ['column'], Domínio: Financas, Similaridade: 0.6685
- Nome: ID_Lancamento_CC, Labels: ['column'], Domínio: Financas, Similaridade: 0.6610
- Nome: ID_Lancamento, Labels: ['column'], Domínio: Financas, Similaridade: 0.6455
- Nome: ID_Conta_Contabil, Labels: ['column'], Domínio: Financas, Similaridade: 0.6392
- Nome: Data_Pedido, Labels: ['column'], Domínio: Vendas, Similaridade: 0.6085
- Nome: ID_Lancamento, Labels: ['column'], Domínio: Financas, Similaridade: 0.6083
- Nome: Valor, Labels: ['column'], Domínio: Financas, Similaridade: 0.5980
- Nome: ID_Receita, Labels: ['column'], Domínio: Producao, Similaridade: 0.5976

```

Figura 13 – Caso 1 - Elementos relevantes do grafo (Fonte: Autor)

² Disponível em: <https://shre.ink/SQ8b>

³ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQmS>

- **Repostas do LLM:** Figura 14⁴

```
--- QUERY SQL GERADA PELO LLM ---  
SELECT  
    LC.*,  
    CC.Nome_Centro_Custo,  
    CONTA.Nome_Conta  
FROM Lancamento_Contabil AS LC  
JOIN Lancamento_Contabil_CC AS LCC  
    ON LC.ID_Lancamento = LCC.ID_Lancamento  
JOIN Centro_Custo AS CC  
    ON LCC.ID_Centro_Custo = CC.ID_Centro_Custo  
JOIN Conta_Contabil AS CONTA  
    ON LC.ID_Conta_Contabil = CONTA.ID_Conta_Contabil;  
--- FIM DA QUERY ---
```

Figura 14 – Caso 1 - Query gerada pelo LLM (Fonte: Autor)

⁴ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQmg>

- **Explicação do LLM para a Query:** Tabela 1

Tabela 1 – Caso de uso 1: Explicação LLM

Explicação do LLM
A consulta SQL acima gera um relatório que mostra os lançamentos contábeis com informações detalhadas, incluindo o centro de custo associado. Vamos analisar a lógica passo a passo: 1. <code>SELECT LC.*, CC.*, CO.Nome_Conta</code>: Esta cláusula seleciona todas as colunas das tabelas <code>Lancamento_Contabil</code> (aliás <code>LC</code>), <code>Centro_Custo</code> (aliás <code>CC</code>), e a coluna <code>Nome_Conta</code> da tabela <code>Conta_Contabil</code> (aliás <code>CO</code>). Isso fornece um conjunto completo de informações para cada lançamento contábil. 2. <code>FROM Lancamento_Contabil AS LC</code>: A consulta inicia na tabela <code>Lancamento_Contabil</code>, que contém as informações básicas de cada lançamento contábil. 3. <code>JOIN Lancamento_Contabil_CC AS LCC ON LC.ID_Lancamento = LCC.ID_Lancamento</code>: Esta é uma junção interna (<code>JOIN</code>) entre <code>Lancamento_Contabil</code> e <code>Lancamento_Contabil_CC</code>. Ela usa <code>ID_Lancamento</code> como chave estrangeira em <code>Lancamento_Contabil_CC</code> e chave primária em <code>Lancamento_Contabil</code> para conectar cada lançamento contábil com seus respectivos centros de custo. Somente os lançamentos com entradas na tabela <code>Lancamento_Contabil_CC</code> serão incluídos. 4. <code>JOIN Centro_Custo AS CC ON LCC.ID_Centro_Custo = CC.ID_Centro_Custo</code>: Esta é outra junção interna que junta a tabela <code>Lancamento_Contabil_CC</code> com a tabela <code>Centro_Custo</code>. Ela utiliza <code>ID_Centro_Custo</code> como chave estrangeira em <code>Lancamento_Contabil_CC</code> e chave primária em <code>Centro_Custo</code> para obter o nome e outras informações do centro de custo associado a cada lançamento. 5. <code>JOIN Conta_Contabil AS CO ON LC.ID_Conta_Contabil = CO.ID_Conta_Contabil</code>: Finalmente, esta junção interna junta <code>Lancamento_Contabil</code> com <code>Conta_Contabil</code> usando <code>ID_Conta_Contabil</code> como chave estrangeira em <code>Lancamento_Contabil</code> e chave primária em <code>Conta_Contabil</code>. Isso adiciona o nome da conta contábil a cada lançamento. Em resumo, a consulta utiliza junções internas para combinar informações de quatro tabelas relacionadas, resultando em um relatório completo de lançamentos contábeis, incluindo detalhes sobre a conta contábil e o centro de custo correspondente. A chave para a construção da query é a existência das chaves estrangeiras que explicitamente conectam as tabelas, permitindo a união dos dados de forma precisa e eficiente.

- **Resultados da Execução da Query (LLM vs Gabarito):** Figura 15⁵ e Figura 16⁶

Consulta SQL executada com sucesso. Retornou 3 registros. ✓

SQL Gerado e Executado. Resultados:

ID_Lancamento	ID_Conta_Contabil	Data_Lancamento	Valor	Tipo_Lancamento	Referencia_Documento	Nome_Centro_Custo	Nome_Conta
1	10001	2024-05-11	70000	Debito	901	Vendas	Ativos Circulantes - Caixa
2	10003	2024-05-11	70000	Credito	901	Vendas	Receita Bruta de Vendas
3	10001	2024-06-02	100000	Debito	903	Vendas	Ativos Circulantes - Caixa

Figura 15 – Caso 1 - Retorno da consulta gerada pelo LLM (Fonte: Autor)

[7] # Caso de Uso 1: Demonstração e Execução dos Casos de Uso (Relatório Contábil)

```
query_example = """
SELECT
    LC.*,
    CC.*,
    CO.Nome_Conta
FROM Lancamento_Contabil AS LC
JOIN Lancamento_Contabil_CC AS LCC
    ON LC.ID_Lancamento = LCC.ID_Lancamento
JOIN Centro_Custo AS CC
    ON LCC.ID_Centro_Custo = CC.ID_Centro_Custo
JOIN Conta_Contabil AS CO
    ON LC.ID_Conta_Contabil = CO.ID_Conta_Contabil;
"""

print("Executing example query:")
run_query_and_display(query_example, conn)
```

↩

Executing example query:

ID_Lancamento	ID_Conta_Contabil	Data_Lancamento	Valor	Tipo_Lancamento	Referencia_Documento	ID_Centro_Custo	Nome_Centro_Custo	Nome_Conta
0	1	10001	2024-05-11	70000.0	Debito	901	1	Vendas Ativos Circulantes - Caixa
1	2	10003	2024-05-11	70000.0	Credito	901	1	Vendas Receita Bruta de Vendas
2	3	10001	2024-06-02	100000.0	Debito	903	1	Vendas Ativos Circulantes - Caixa

Figura 16 – Caso 1 - Retorno da consulta gabarito (Fonte: Autor)

4.2.2 Caso de uso 2: Conexão faltante (Contábil vs. Vendas)

- **Pergunta do Usuário:** “Preciso de um relatório que conecte os lançamentos contábeis com os dados de vendas, como o total das faturas e os clientes. Me mostre a conexão.”
- **Discussão:** Este cenário foi projetado para testar a capacidade do sistema em identificar a ausência de uma conexão direta e clara entre os domínios de Contabilidade e Vendas no modelo de dados disponível. No esquema do banco de dados, não há uma chave estrangeira explícita ou um caminho de junção óbvio que ligue diretamente os lançamentos contábeis às faturas de venda ou dados de clientes de forma granular que satisfaça a pergunta de negócio.

⁵ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQmr>

⁶ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQmd>

- **Elementos Relevantes do Grafo: Figura 17⁷**

```

=== Teste Caso de Uso 2: Conexão Faltante (Contábil vs Vendas) ===

Pergunta: Preciso de um relatório que conecte os lançamentos contábeis com os dados de vendas da empresa.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.05370866687464714, -0.13286645846366882, -0.19228555262888776, -0.28640817284584845, -0.17016679913143158]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: ID_Lancamento, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5370
- Nome: ID_Pedido, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5273
- Nome: ID_Lancamento_CC, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5250
- Nome: Lancamento_Contabil, Labels: ['Table'], Domínio: Financas, Similaridade: 0.5219
- Nome: Tipo_Lancamento, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5177
- Nome: Quantidade_Disponivel, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.5150
- Nome: ID_Fatura_Venda, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5138
- Nome: VendasContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.5132
- Nome: ID_Conta_Contabil, Labels: ['Column'], Domínio: Financas, Similaridade: 0.5063
- Nome: idLancamento, Labels: ['Property'], Domínio: None, Similaridade: 0.5058

```

Figura 17 – Caso 2 - Elementos relevantes do grafo (Fonte: Autor)

- **Repostas do LLM: Figura 18⁸**

```

--- QUERY SQL GERADA PELO LLM ---
NÃO FOI POSSÍVEL GERAR A CONSULTA SQL COM BASE NO ESQUEMA DISPONÍVEL, OU A CONEXÃO ENTRE OS DADOS NÃO É DIRETA. Por favor, revise o modelo lógico ou a pergunta.
--- FIM DA QUERY ---

```

Figura 18 – Caso 2 - Query gerada pelo LLM (Fonte: Autor)

- **Explicação do LLM para a Query:** Não houve retorno de uma query, uma vez que não foi possível estabelecer uma relação entre os objetos do grafo. Esse era o comportamento esperado pelo LLM.
- **Resultados da Execução da Query (LLM vs Gabarito):** Para este cenário, não há uma *query* SQL a ser executada com resultados visuais, pois o comportamento esperado do sistema era justamente o de não gerar uma *query* SQL devido à falta de uma conexão direta no modelo de dados. Isso demonstra um comportamento inteligente do LLM, que, conforme instruído no *prompt*, prioriza a confiabilidade da resposta em vez de tentar inferir uma conexão ambígua ou inexistente.

4.2.3 Caso de uso 3: Conexão faltante (Funcionário vs. Centro de custo)

- **Pergunta do Usuário:** “Gere um relatório que conecte os funcionários da empresa com os centros de custo, mostrando o nome do funcionário e o nome do centro de custo. Me diga como eles se relacionam.”
- **Discussão:** Similar ao cenário anterior, este caso de uso visa validar a capacidade do sistema em reconhecer e comunicar a ausência de uma conexão direta e pré-definida

⁷ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQmm>

⁸ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ10>

entre dois nós (Funcionário e Centro de Custo) que podem ter relevância conceitual no negócio, mas não possuem um relacionamento explícito de chave estrangeira (FK) no modelo de dados ou um caminho de junção óbvio para essa conexão específica. O protótipo é testado para verificar se prioriza a integridade do modelo de dados sobre a inferência especulativa.

- **Elementos Relevantes do Grafo:** Figura 19⁹

```

=== Teste Caso de Uso 3: Conexão Faltante (Funcionário vs. Centro de Custo) ===

Pergunta: Gere um relatório que conecte os funcionários da empresa com os centros de custo, mostrando o nome do funcionário e o nome do centro de custo. Me diga como eles se relacionam.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [0.30864281821258916, 0.1221136823296547, -0.13311287760734558, -0.16725224256515503, -0.43915875063705444]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: ID_Centro_Custo, Labels: ['Column'], Domínio: Financas, Similaridade: 0.7034
- Nome: Nome_Centro_Custo, Labels: ['Column'], Domínio: Financas, Similaridade: 0.6802
- Nome: ID_Centro_Custo, Labels: ['Column'], Domínio: Financas, Similaridade: 0.6414
- Nome: VendasContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6184
- Nome: RecursosHumanosContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6078
- Nome: FinancasContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6028
- Nome: nomeCentroCusto, Labels: ['Property'], Domínio: None, Similaridade: 0.5849
- Nome: idCentroCusto, Labels: ['Property'], Domínio: None, Similaridade: 0.5826
- Nome: Centro_Custo, Labels: ['Table'], Domínio: Financas, Similaridade: 0.5821
- Nome: TecnologiainformacaoContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.5772

```

Figura 19 – Caso 3 - Elementos relevantes do grafo (Fonte: Autor)

- **Repostas do LLM:** Figura 20¹⁰

```

--- QUERY SQL GERADA PELO LLM ---
NÃO FOI POSSÍVEL GERAR A CONSULTA SQL COM BASE NO ESQUEMA DISPONÍVEL, OU A CONEXÃO ENTRE OS DADOS NÃO É DIRETA. Por favor, revise o modelo lógico ou a pergunta.
--- FIM DA QUERY ---

```

Figura 20 – Caso 3 - Query gerada pelo LLM (Fonte: Autor)

- **Explicação do LLM para a Query:** Não houve retorno de uma *query*, uma vez que não foi possível estabelecer uma relação entre os objetos do grafo. Esse era o comportamento esperado pelo LLM.
- **Resultados da Execução da Query (LLM vs Gabarito):** Para este cenário, o sistema se comportou conforme o esperado, abstendo-se de gerar uma *query* SQL devido à inexistência de uma relação direta e explícita no esquema do banco de dados que pudesse conectar as tabelas **Funcionario** e **Centro_Custo**. Este resultado reforça a confiabilidade da abordagem, que evita a geração de consultas potencialmente incorretas ou alucinadas em situações de ausência de contexto de conexão claro.

⁹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1V>

¹⁰ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1N>

4.2.4 Caso de uso 4: Uso de ontologia

- **Pergunta do Usuário:** “Liste os diferentes tipos de produtos voadores que a empresa vende, mostrando seus nomes e descrições. Me explique como você identificou esses produtos.”
- **Discussão:** Este caso de uso é fundamental para demonstrar a capacidade do sistema em alavancar o conhecimento semântico da ontologia para responder a perguntas que utilizam conceitos abstratos ou termos de negócio que podem não estar explicitamente presentes nas colunas do modelo físico do banco de dados. A pergunta sobre produtos voadores não se refere a uma coluna direta, mas a uma categoria ou característica definida na ontologia.
- **Elementos Relevantes do Grafo:** Figura 21¹¹

```

=== Teste Caso de Uso 4: Uso de Ontologia (Produtos Voadores) ===

Pergunta: Liste os diferentes tipos de produtos voadores que a empresa vende, mostrando seus nomes e descrições. Me explique como você identificou esses produtos.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.27719351649284363, 0.14288035035133362, -0.1539510041475296, -0.22593829035758972, 0.1957913190126419]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: EquipamentoVoador, Labels: ['Concept'], Domínio: None, Similaridade: 0.7272
- Nome: ProdutoContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6939
- Nome: MochilaVoadora, Labels: ['Concept'], Domínio: None, Similaridade: 0.6441
- Nome: ID_Produto, Labels: ['Column'], Domínio: Produto, Similaridade: 0.6355
- Nome: ProducaoContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6309
- Nome: Veiculo, Labels: ['Concept'], Domínio: None, Similaridade: 0.6088
- Nome: precoVendaItemPedido, Labels: ['Property'], Domínio: None, Similaridade: 0.5967
- Nome: EquipamentoFabricacao, Labels: ['Concept'], Domínio: None, Similaridade: 0.5907
- Nome: Quantidade_Produzir, Labels: ['Column'], Domínio: Producao, Similaridade: 0.5868
- Nome: VendasContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.5861

```

Figura 21 – Caso 4 - Elementos relevantes do grafo (Fonte: Autor)

- **Respostas do LLM:** Figura 22¹²

```

--- QUERY SQL GERADA PELO LLM ---
SELECT T1.Nome_Produto, T1.Descricao_Produto
FROM Produto AS T1
INNER JOIN Categoria_Produto AS T2 ON T1.ID_Categoria_Produto = T2.ID_Categoria_Produto
WHERE T1.Nome_Produto LIKE '%Voador%' ;
--- FIM DA QUERY ---

```

Figura 22 – Caso 4 - Query gerada pelo LLM (Fonte: Autor)

¹¹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1E>

¹² Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1R>

• Explicação do LLM para a Query: Tabela 2

Tabela 2 – Caso de uso 4: Explicação LLM

Explicação do LLM
Explicação da Lógica da Query: A consulta SQL acima busca informações sobre produtos voadores a partir das tabelas ‘Produto’ e ‘Categoria_Produto’. 1. **Seleção de Colunas:** A cláusula ‘SELECT T1.Nome_Produto, T1.Descricao_Produto’ especifica que a consulta deve retornar o nome e a descrição do produto. ‘T1’ é um alias dado à tabela ‘Produto’ para simplificar a escrita da consulta. 2. **Junção de Tabelas (JOIN):** Um ‘INNER JOIN’ é usado para conectar a tabela ‘Produto’ (T1) com a tabela ‘Categoria_Produto’ (T2). A condição de junção ‘ON T1.ID_Categoria_Produto = T2.ID_Categoria_Produto’ relaciona os produtos com suas respectivas categorias através da chave estrangeira ‘ID_Categoria_Produto’ presente na tabela ‘Produto’ que referencia a chave primária ‘ID_Categoria_Produto’ na tabela ‘Categoria_Produto’. Isso garante que apenas produtos com categorias registradas sejam incluídos no resultado. Embora a tabela ‘Categoria_Produto’ não seja diretamente usada na seleção final, o ‘JOIN’ é necessário para garantir a integridade dos dados, caso a coluna ‘ID_Categoria_Produto’ seja obrigatória na tabela ‘Produto’. 3. **Filtragem de Dados (WHERE):** A cláusula ‘WHERE T1.Nome_Produto LIKE ‘%Voador%’’ filtra os resultados para incluir apenas os produtos cujo nome contenha a palavra "Voador". O operador ‘LIKE’ com o caractere curinga ‘%’ permite encontrar correspondências parciais. **Identificação dos Produtos:** Os produtos voadores são identificados pela busca de correspondência de texto no campo ‘Nome_Produto’ da tabela ‘Produto’. A consulta usa a palavra "Voador" como critério de busca, assumindo que os nomes dos produtos voadores incluem esta palavra. Esta é uma abordagem simples, porém pode ser necessário um método mais sofisticado se os nomes dos produtos não seguirem um padrão consistente, ou se outros critérios de identificação forem relevantes. A inclusão da tabela ‘Categoria_Produto’ no ‘JOIN’ permite expandir a busca, se necessário, para incluir outras propriedades ou categorias relacionadas a produtos voadores. Se a empresa utilizar uma coluna específica para identificar o tipo de produto (como "Tipo_Produto" com valor "Voador"), a consulta poderia ser otimizada para usar essa coluna diretamente.

- **Resultados da Execução da Query (LLM vs Gabarito):** Figura 23¹³ e Figura 24¹⁴

Consulta SQL executada com sucesso. Retornou 1 registros. ✓

SQL Gerado e Executado. Resultados:

Nome_Produto	Descricao_Produto
Mochila Voadora AeroPack	Mochila pessoal com propulsão a jato.

Figura 23 – Caso 4 - Retorno da consulta gerada pelo LLM (Fonte: Autor)

```
[ ] # Caso de Uso 4: Demonstração e Execução dos Casos de Uso (Uso de Ontologia: Produtos Voadores)
query_example = """
SELECT T1.Nome_Produto, T1.Descricao_Produto
FROM Produto AS T1
INNER JOIN Categoria_Produto AS T2 ON T1.ID_Categoria_Produto = T2.ID_Categoria_Produto
WHERE T2.Nome_Categoria LIKE '%Voador%'
"""

print("Executing example query:")
run_query_and_display(query_example, conn)
```

Executing example query:

	Nome_Produto	Descricao_Produto
0	Mochila Voadora AeroPack	Mochila pessoal com propulsão a jato.

Figura 24 – Caso 4 - Retorno da consulta gabarito (Fonte: Autor)

- **Análise dos resultados:** Este cenário demonstrou a capacidade do sistema em interpretar a intenção do usuário que transcende a simples busca por nomes de colunas, aproveitando o enriquecimento semântico proporcionado pela ontologia no grafo de conhecimento. O LLM foi capaz de correlacionar o conceito abstrato de **produtos voadores** com a categoria de produtos no modelo relacional, gerando uma consulta SQL que filtra por `Nome_Categoria LIKE '%Voador%'`. Este é um exemplo claro de como a camada de conhecimento semântico permite ao sistema responder a perguntas de negócio de forma mais inteligente e contextualizada, mesmo quando os termos não são idênticos no esquema físico.

¹³ Figuras em resolução ampliada disponíveis em: <https://shre.in/SQ1F>

¹⁴ Figuras em resolução ampliada disponíveis em: <https://shre.in/SQ1y>

4.2.5 Caso de uso 5: Governança de dados (Mascaramento de campo sensível)

- **Pergunta do Usuário:** “Mostre o nome, e-mail e data de cadastro dos clientes, mas mascare qualquer dado sensível no resultado.”
- **Discussão:** Este caso de uso foi concebido para testar a capacidade do sistema em integrar conceitos de governança de dados, especificamente o mascaramento de informações sensíveis. Embora o grafo de conhecimento contenha metadados de governança (como a Classificação e Confidencialidade em nós de coluna), a complexidade reside em o LLM interpretar a solicitação de mascarar e traduzi-la para uma função SQL apropriada, sem uma *tool* ou um mecanismo de mascaramento explícito e pré-implementado.
- **Elementos Relevantes do Grafo:** Figura 25¹⁵

```
Pergunta: Mostre o nome, e-mail e data de cadastro dos clientes, mas mascare qualquer dado sensível no resultado.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.23738567531108856, 0.10102088004350662, -0.015775347128510475, -0.4507678747177124, -0.07483650743961334]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (0 registros filtrados por similaridade > 0.5):
Nenhum elemento relevante encontrado na busca semântica do grafo (abaixo do limiar de similaridade).
```

Figura 25 – Caso 5 - Elementos relevantes do grafo (Fonte: Autor)

- **Respostas do LLM:** Figura 26¹⁶

```
--- QUERY SQL GERADA PELO LLM ---
NÃO FOI POSSÍVEL GERAR A CONSULTA SQL COM BASE NO ESQUEMA DISPONÍVEL, OU A CONEXÃO ENTRE OS DADOS NÃO É DIRETA. Por favor, revise o modelo lógico ou a pergunta.
--- FIM DA QUERY ---
```

Figura 26 – Caso 5 - Query gerada pelo LLM (Fonte: Autor)

- **Explicação do LLM para a Query:** Não houve retorno de uma query, uma vez que não foi possível estabelecer uma relação entre os objetos do grafo. Esse era o comportamento esperado pelo LLM.
- **Resultados da Execução da Query (LLM vs Gabarito):** Para este cenário, o sistema não gerou uma *query* SQL, conforme indicado pela resposta do LLM. Este resultado, embora não produza uma consulta para execução, é um aprendizado importante sobre as limitações atuais da abordagem para governança ativa. O LLM, apesar de ter acesso a metadados de governança no grafo, não foi capaz de inferir a necessidade de aplicar uma função de mascaramento (como `SUBSTR` ou `REPLACE` em

¹⁵ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1Z>

¹⁶ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1v>

SQL) ou de invocar um mecanismo de proteção de dados complexo a partir de uma instrução em linguagem natural. Isso sugere que, para funcionalidades de governança mais sofisticadas, seriam necessárias *tools* específicas ou regras mais explícitas no *prompt*, direcionando o LLM para as ações de mascaramento ou anonimização.

4.2.6 Caso de uso 6: Conexões diretas de produto (Jornada completa)

- **Pergunta do Usuário:** “Para cada produto, mostre seu nome e categoria, todos os pedidos em que ele foi incluído (com a quantidade comprada), sua quantidade disponível em estoque, as receitas de produção relacionadas e as ordens de produção associadas. Inclua todas as colunas relevantes e explique as conexões.”
- **Discussão:** Este cenário foi concebido para testar a capacidade do sistema em construir uma *query* SQL complexa que explora múltiplas relações diretas a partir de uma nó central (**Produto**). O desafio para o LLM é identificar e conectar corretamente diversas tabelas por meio de *LEFT JOINs*, garantindo que todos os produtos sejam incluídos, mesmo que não tenham registros correspondentes em todas as tabelas relacionadas (por exemplo, um produto sem pedidos ou sem receita de produção).
- **Elementos Relevantes do Grafo:** Figura 27¹⁷

```

=== Teste Caso de Uso 6: Conexões Diretas de Produto ===

Pergunta: Para cada produto, mostre seu nome e categoria, todos os pedidos em que ele foi incluído (com a quantidade comprada), sua quantidade disponível em estoque, as re
DEBUG: Embedding da pergunta (primeiros 5 elementos): [0.02860591746866703, -0.09414351731538773, -0.2591436803340912, -0.1772819310426712, 0.1939496397972107]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: ProdutoContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.7016
- Nome: QuantidadeDisponível, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.6934
- Nome: ProducaoContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.6895
- Nome: QuantidadeProduzir, Labels: ['Column'], Domínio: Producao, Similaridade: 0.6777
- Nome: ID Receita, Labels: ['Column'], Domínio: Producao, Similaridade: 0.6724
- Nome: ID Categoria_Produto, Labels: ['Column'], Domínio: Produto, Similaridade: 0.6584
- Nome: ID_Produto, Labels: ['Column'], Domínio: Producao, Similaridade: 0.6499
- Nome: QuantidadeDisponível, Labels: ['Property'], Domínio: None, Similaridade: 0.6493
- Nome: ID_Produto, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.6444
- Nome: EquipamentoFabricacao, Labels: ['Concept'], Domínio: None, Similaridade: 0.6390

```

Figura 27 – Caso 6 - Elementos relevantes do grafo (Fonte: Autor)

¹⁷ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1j>

- Repostas do LLM: Figura 28¹⁸

```
--- QUERY SQL GERADA PELO LLM ---  
SELECT  
    P.Nome_Produto,  
    CP.Nome_Categoria,  
    IP.ID_Pedido,  
    IP.Quantidade,  
    E.Quantidade_Disponivel,  
    RP.ID_Receita,  
    OP.ID_Ordem_Producao  
FROM Produto AS P  
JOIN Categoria_Produto AS CP  
    ON P.ID_Categoria_Produto = CP.ID_Categoria_Produto  
LEFT JOIN Item_Pedido AS IP  
    ON P.ID_Produto = IP.ID_Produto  
LEFT JOIN Estoque AS E  
    ON P.ID_Produto = E.ID_Produto  
LEFT JOIN Receita_Produto AS RP  
    ON P.ID_Produto = RP.ID_Produto  
LEFT JOIN Producao_Ordem AS OP  
    ON P.ID_Produto = OP.ID_Produto;  
--- FIM DA QUERY ---
```

Figura 28 – Caso 6 - Query gerada pelo LLM (Fonte: Autor)

¹⁸ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ17>

- **Explicação do LLM para a Query:** Tabela 3

Tabela 3 – Caso de uso 6: Explicação LLM

Explicação do LLM
Explicação da Lógica da Query: A consulta busca informações detalhadas sobre produtos, integrando dados de várias tabelas do banco de dados. A tabela central é ‘Produto’, que contém informações básicas sobre cada produto (Nome_Produto e ID_Categoria_Produto). * **JOIN com ‘Categoria_Produto’: ** Um ‘JOIN’ interno (‘INNER JOIN’) é usado para unir a tabela ‘Produto’ com a tabela ‘Categoria_Produto’ usando ‘P.ID_Categoria_Produto = CP.ID_Categoria_Produto’. Isso permite obter o nome da categoria de cada produto, adicionando contexto adicional aos dados do produto. * **LEFT JOIN com ‘Item_Pedido’: ** Um ‘LEFT JOIN’ com a tabela ‘Item_Pedido’ é utilizado para incluir informações sobre os pedidos que incluem cada produto. A condição de junção é ‘P.ID_Produto = IP.ID_Produto’. O ‘LEFT JOIN’ garante que todos os produtos sejam incluídos no resultado, mesmo aqueles que não tenham entradas na tabela ‘Item_Pedido’ (neste caso, os campos relacionados a ‘Item_Pedido’ serão ‘NULL’). * **LEFT JOIN com ‘Estoque’: ** Similarmente, um ‘LEFT JOIN’ com a tabela ‘Estoque’ é usado para obter a quantidade disponível de cada produto em estoque (‘P.ID_Produto = E.ID_Produto’). Novamente, o ‘LEFT JOIN’ garante que todos os produtos sejam incluídos, mesmo que não possuam registro de estoque. * **LEFT JOIN com ‘Receita_Produto’: ** Um ‘LEFT JOIN’ com a tabela ‘Receita_Produto’ recupera os IDs das receitas de produção associadas a cada produto (‘P.ID_Produto = RP.ID_Produto’). A ausência de uma receita para um produto resultará em ‘NULL’ para ‘ID_Receita’. * **LEFT JOIN com ‘Producao_Ordem’: ** Finalmente, um ‘LEFT JOIN’ com a tabela ‘Producao_Ordem’ é realizado para obter os IDs das ordens de produção relacionadas a cada produto (‘P.ID_Produto = OP.ID_Produto’). Produtos sem ordens de produção terão ‘ID_Ordem_Producao’ como ‘NULL’. A consulta utiliza ‘LEFT JOIN’ em vez de ‘INNER JOIN’ nas tabelas ‘Item_Pedido’, ‘Estoque’, ‘Receita_Produto’ e ‘Producao_Ordem’ para garantir que todos os produtos sejam retornados, mesmo que não tenham registros correspondentes nas outras tabelas. O resultado final é uma tabela contendo o nome do produto, nome da categoria, detalhes dos pedidos (ID e quantidade), quantidade em estoque, IDs das receitas de produção e IDs das ordens de produção para cada produto.

- **Resultados da Execução da Query (LLM vs Gabarito):** Figura 29¹⁹ e Figura 30²⁰

Consulta SQL executada com sucesso. Retornou 5 registros. ✓

SQL Gerado e Executado. Resultados:

Nome_Produto	Nome_Categoria	ID_Pedido	Quantidade	Quantidade_Disponivel	ID_Receita	ID_Ordem_Producao
Quadríciclo X-Treme	Veículos	301	2	50		
Quadríciclo X-Treme	Veículos	303	1	50		
Mochila Voadora AeroPack	Equipamentos Voadores	302	1	10		
Bike Montanha Carbono	Veículos	303	3		701	801
Capacete Adventure Pro	Acessórios					

Figura 29 – Caso 6 - Retorno da consulta gerada pelo LLM (Fonte: Autor)

```
# Caso de Uso 6: Demonstração e Execução dos Casos de Uso (Conexões Diretas de Produto)
query_example = """
SELECT
    P.Nome_Produto,
    CP.Nome_Categoria,
    IP.ID_Pedido,
    IP.Quantidade,
    E.Quantidade_Disponivel,
    RP.ID_Receita,
    OP.ID_Ordem_Producao
FROM Produto AS P
JOIN Categoria_Produto AS CP
    ON P.ID_Categoria_Produto = CP.ID_Categoria_Produto
LEFT JOIN Item_Pedido AS IP
    ON P.ID_Produto = IP.ID_Produto
LEFT JOIN Estoque AS E
    ON P.ID_Produto = E.ID_Produto
LEFT JOIN Receita_Produto AS RP
    ON P.ID_Produto = RP.ID_Produto
LEFT JOIN Producao_Ordem AS OP
    ON P.ID_Produto = OP.ID_Produto;
"""

print("Executing example query:")
run_query_and_display(query_example, conn)
```

Executing example query:

	Nome_Produto	Nome_Categoria	ID_Pedido	Quantidade	Quantidade_Disponivel	ID_Receita	ID_Ordem_Producao
0	Quadríciclo X-Treme	Veículos	301.0	2.0	50.0	NaN	NaN
1	Quadríciclo X-Treme	Veículos	303.0	1.0	50.0	NaN	NaN
2	Mochila Voadora AeroPack	Equipamentos Voadores	302.0	1.0	10.0	NaN	NaN
3	Bike Montanha Carbono	Veículos	303.0	3.0	NaN	701.0	801.0
4	Capacete Adventure Pro	Acessórios	NaN	NaN	NaN	NaN	NaN

Figura 30 – Caso 6 - Retorno da consulta gabarito (Fonte: Autor)

- **Análise dos resultados:** A resposta do sistema para este cenário demonstrou com sucesso a capacidade de construir uma consulta SQL que integra informações de múltiplas tabelas relacionadas, utilizando *LEFT JOINS* de forma apropriada para garantir a inclusão de todos os produtos, independentemente de terem correspondência em todas as tabelas acessadas. A precisão dos *JOINS* e a seleção das colunas

¹⁹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ15>

²⁰ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1S>

relevantes indicam uma compreensão robusta da estrutura de dados e das relações contidas no grafo de conhecimento. Este caso ilustra a eficácia da abordagem em fornecer uma visão 360 graus de um nó complexo como **Produto**.

4.2.7 Caso de uso 7: Meta-conhecimento (Relações da tabela produto)

- **Pergunta do Usuário:** “Quantas relações diretas a tabela Produto tem em nosso modelo de dados? Me diga quais são essas relações e as tabelas envolvidas.”
- **Discussão:** Este cenário explorou a capacidade do sistema em consultar o meta-conhecimento sobre o próprio esquema do banco de dados, em vez de dados transacionais. A intenção era verificar se o LLM conseguiria compreender uma pergunta sobre a estrutura e os relacionamentos diretos de um nó específico (**Produto**), acessando informações sobre chaves estrangeiras. Este é um desafio elevado, pois exige que o LLM não apenas gere SQL, mas raciocine sobre o esquema.
- **Elementos Relevantes do Grafo:** Figura 31²¹

```

=== Teste Caso de Uso 7: Meta-Conhecimento (Relações da Tabela Produto) ===

Pergunta: Quantas relações diretas a tabela Produto tem em nosso modelo de dados? Me diga quais são essas relações e as tabelas envolvidas.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.3524231816635895, -0.02542283944785595, -0.0820685401558876, -0.015204411000013351, -0.43305808305740356]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: QuantidadeDisponivel, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.6631
- Nome: temRetencaoDadosAnos, Labels: ['Property'], Domínio: None, Similaridade: 0.6201
- Nome: Estoque, Labels: ['Table'], Domínio: Cadeia Logística, Similaridade: 0.6164
- Nome: Materia_Prima, Labels: ['Table'], Domínio: Producao, Similaridade: 0.6041
- Nome: ID_Produto, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.5878
- Nome: Departamento, Labels: ['Table'], Domínio: RH, Similaridade: 0.5736
- Nome: Nome_Categoria, Labels: ['Column'], Domínio: Produto, Similaridade: 0.5662
- Nome: Quantidade_Produzir, Labels: ['Column'], Domínio: Producao, Similaridade: 0.5652
- Nome: Recebimento_Materia_Prima, Labels: ['Table'], Domínio: Cadeia Logística, Similaridade: 0.5582
- Nome: quantidadeDisponivel, Labels: ['Property'], Domínio: None, Similaridade: 0.5579

```

Figura 31 – Caso 7 - Elementos relevantes do grafo (Fonte: Autor)

- **Respostas do LLM:** Figura 32²²

```

--- QUERY SQL GERADA PELO LLM ---
SELECT COUNT(*) AS Numero_Relacoes,
       GROUP_CONCAT(CASE WHEN T1.ID_Produto IS NOT NULL THEN 'Produto -> Estoque' ELSE NULL END || ',' ||
                     CASE WHEN T2.ID_Produto IS NOT NULL THEN 'Produto -> Item_Pedido' ELSE NULL END || ',' ||
                     CASE WHEN T3.ID_Produto IS NOT NULL THEN 'Produto -> Producao_Ordem' ELSE NULL END || ',' ||
                     CASE WHEN T4.ID_Produto IS NOT NULL THEN 'Produto -> Receita_Produto' ELSE NULL END, ',') AS Relacoes
FROM Produto AS P
LEFT JOIN Estoque AS T1 ON P.ID_Produto = T1.ID_Produto
LEFT JOIN Item_Pedido AS T2 ON P.ID_Produto = T2.ID_Produto
LEFT JOIN Producao_Ordem AS T3 ON P.ID_Produto = T3.ID_Produto
LEFT JOIN Receita_Produto AS T4 ON P.ID_Produto = T4.ID_Produto;
--- FIM DA QUERY ---

```

Figura 32 – Caso 7 - Query gerada pelo LLM (Fonte: Autor)

²¹ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1g>


²² Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1I>

- Explicação do LLM para a Query: Tabela 4

Tabela 4 – Caso de uso 7: Explicação LLM

Explicação do LLM
Use SELECT para selecionar o número total de relações e as relações em si. A função GROUP_CONCAT concatena os nomes das relações encontradas. Use LEFT JOIN para unir a tabela ‘Produto’ com as tabelas ‘Estoque’, ‘Item_Pedido’, ‘Producao_Ordem’ e ‘Receita_Produto’. Cada JOIN usa a chave primária ‘ID_Produto’ da tabela ‘Produto’ e a respectiva chave estrangeira ‘ID_Produto’ em cada uma das outras tabelas. Isto garante que todas as relações, mesmo que não haja correspondência em algumas tabelas, sejam contabilizadas. Não há cláusula WHERE, pois queremos contar todas as relações diretas da tabela ‘Produto’. A query retorna o número total de relações diretas que a tabela ‘Produto’ possui, que é 4, e uma lista concatenada com o nome de cada uma das relações identificadas através das chaves estrangeiras. A função ‘GROUP_CONCAT’ agrupa e concatena os resultados para facilitar a visualização. O uso de CASE permite lidar com o caso em que uma relação não seja encontrada, evitando erros.

- **Resultados da Execução da Query (LLM vs Gabarito):** Figura 33²³ Para o



```

Consulta SQL executada com sucesso. Retornou 1 registros. ✓

SQL Gerado e Executado. Resultados:
+-----+-----+
| Numero_Relacoes | Relacoes |
+=====+=====+
|                5 |          |
+-----+-----+

```

Figura 33 – Caso 7 - Retorno da consulta gerada pelo LLM (Fonte: Autor)

gabarito, não era esperado uma query, mas a base foi o modelo lógico, como mostra a figura 34.

- **Análise dos resultados:** Este cenário apresentou um resultado surpreendente e revelador. Embora a expectativa inicial fosse de que o sistema comunicasse a impossibilidade de gerar a consulta (dada a complexidade de inferir sobre o meta-esquema). Foram realizadas algumas execuções, sendo o caso de teste mais volátil, mas ainda sim o LLM demonstrou uma capacidade criativa de inferência, "alucinando" consultas válidas, ora utilizando as tabelas de sistema do SQLite (`sqlite_master` e `pragma_foreign_key_list`) para tentar responder à pergunta sobre as relações da tabela `Produto`, ora elaborando *queries* complexas com lógica sofisticada. A *query* gerada foi sintaticamente correta e, em um ambiente SQLite, de fato retornaria a contagem de relações da tabela `Produto`, demonstrando um raciocínio sobre a estrutura interna do banco de dados que não era explicitamente buscado no grafo de conhecimento. Este comportamento destaca tanto o potencial do LLM em lidar com questões de meta-conhecimento quanto a necessidade de controle e validação rigorosa sobre suas inferências mais criativas em ambientes de produção. O aprendizado aqui é a demonstração da capacidade do LLM em explorar o próprio ambiente para tentar satisfazer a pergunta, mesmo que de uma forma não previamente explicitada na camada do grafo.

4.2.8 Caso de uso 8: Meta-conhecimento (Relações da tabela produto com outras tabelas)

- **Pergunta do Usuário:** “Me traga um relatório sobre a tabela produto mostrando todas as relações que ela tem com outras tabelas.”

²³ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1k>




Figura 34 – Caso 7 - Retorno da consulta gabarito (Fonte: Autor)

- **Discussão:** Este cenário é uma variação do anterior, com foco também em meta-conhecimento, mas com uma solicitação mais abrangente por todas as relações. O objetivo é verificar se o LLM consegue ir além da simples identificação de uma FK e fornecer um panorama mais completo das conexões do nó **Produto** no esquema, novamente exigindo um raciocínio sobre a estrutura do banco de dados.
- **Elementos Relevantes do Grafo:** Figura 35²⁴
- **Repostas do LLM:** Figura 36²⁵
- **Explicação do LLM para a Query:** Não houve retorno de uma *query*, uma vez que não foi possível estabelecer uma relação entre os objetos do grafo. Esse era o comportamento esperado pelo LLM.
- **Resultados da Execução da Query (LLM vs Gabarito):** Para este cenário, o sistema não gerou uma *query* SQL, indicando a falta de uma conexão di-

²⁴ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1H>

²⁵ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQ1m>

```

=== Teste Caso de Uso 8: Meta-Conhecimento (Relações da Tabela Produto com Outras Tabelas) ===

Pergunta: Me traga um relatório sobre a tabela produto mostrando todas as relações que ela tem com outras tabelas.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.25008273124694824, 0.0720396563410759, -0.2066703736782074, -0.1225271075963974, -0.21513274312019348]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: Item_Receita, Labels: ['Table'], Domínio: Producao, Similaridade: 0.6613
- Nome: ID_Receita, Labels: ['Column'], Domínio: Producao, Similaridade: 0.6604
- Nome: Materia_Prima, Labels: ['Table'], Domínio: Producao, Similaridade: 0.6550
- Nome: Receita_Produto, Labels: ['Table'], Domínio: Producao, Similaridade: 0.6524
- Nome: ID_Receita, Labels: ['Column'], Domínio: Producao, Similaridade: 0.6510
- Nome: Categoria_Produto, Labels: ['Table'], Domínio: Produto, Similaridade: 0.6457
- Nome: Nome_Categoria, Labels: ['Column'], Domínio: Produto, Similaridade: 0.6358
- Nome: ID_Produto, Labels: ['Column'], Domínio: Cadeia_Logística, Similaridade: 0.6312
- Nome: ID_Categoria_Produto, Labels: ['Column'], Domínio: Produto, Similaridade: 0.6312
- Nome: Produto, Labels: ['Table'], Domínio: Produto, Similaridade: 0.6264

```

Figura 35 – Caso 8 - Elementos relevantes do grafo (Fonte: Autor)

```

--- QUERY SQL GERADA PELO LLM ---
NÃO FOI POSSÍVEL GERAR A CONSULTA SQL COM BASE NO ESQUEMA DISPONÍVEL, OU A CONEXÃO ENTRE OS DADOS NÃO É DIRETA. Por favor, revise o modelo lógico ou a pergunta.
--- FIM DA QUERY ---

```

Figura 36 – Caso 8 - Query gerada pelo LLM (Fonte: Autor)

reta para atender à solicitação. Este resultado reforça o aprendizado do **Cenário 7**: embora o LLM possa tentar uma inferência criativa para meta-conhecimento quando há uma tentativa de mapeamento direto para tabelas de sistema (como em `pragma_foreign_key_list`), uma solicitação mais genérica por todas as relações sem um caminho explícito de extração no *prompt* ou via *tools* dedicadas ainda é um desafio. Isso sugere que a capacidade de autorreflexão do LLM sobre o esquema em um nível abstrato ainda necessita de refinamentos, como a introdução de *tools* específicas para consulta de meta-esquemas ou uma estrutura mais rica para representar explicitamente todos os tipos de relações no grafo para o LLM.

4.2.9 Caso de uso 9: Relatório completo de produto (Uso extenso da ontologia)

- **Pergunta do Usuário:** “Me traga um relatório completo de produto mostrando todos os campos sobre ele. Faça relação (*join*) com as tabelas que tiverem relações e me traga as colunas delas também no relatório.”
- **Discussão:** Este cenário é um teste abrangente para a capacidade do sistema em integrar múltiplas fontes de informação – dados transacionais do banco de dados e metadados do esquema – para construir um relatório complexo. O desafio para o LLM é identificar e conectar corretamente diversos nós relacionadas ao nó **Produto** por meio de *JOINS*, incluindo todas as colunas relevantes das tabelas envolvidas, conforme a solicitação do usuário.
- **Elementos Relevantes do Grafo:** Figura 37²⁶

²⁶ Figuras em resolução ampliada disponíveis em: <https://shre.in/SQUV>

```

--- Teste Caso de Uso 9: Relatório Completo de Produto com Relações ---
Pergunta: Me traga um relatório completo de produto mostrando todos os campos sobre ele. Faça relação (join) com as tabelas que tiverem relações e me traga as colunas delas também no relatório.
DEBUG: Embedding da pergunta (primeiros 5 elementos): [-0.019273266196250916, -0.046650782227516174, -0.1615176208666992, -0.0018757832003757358, -0.05403288081288338]...
DEBUG: Tamanho do Embedding da pergunta: 384

DEBUG: Recuperando embeddings de ['Table', 'Column', 'Concept', 'Property'] do grafo para busca semântica...
DEBUG: Total de nós com embeddings recuperados: 278
DEBUG: Resultados da busca semântica no grafo (10 registros filtrados por similaridade > 0.5):
- Nome: Nome_Categoria, Labels: ['Column'], Domínio: Produto, Similaridade: 0.6346
- Nome: Quantidade_Disponivel, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.6186
- Nome: ID_Receita, Labels: ['Column'], Domínio: Produção, Similaridade: 0.6137
- Nome: Unidade_Medida, Labels: ['Column'], Domínio: Produção, Similaridade: 0.6101
- Nome: ID_Produto, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.6066
- Nome: ID_Estoque, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.5992
- Nome: ID_Pedido, Labels: ['Column'], Domínio: Cadeia Logística, Similaridade: 0.5986
- Nome: ID_Receita, Labels: ['Column'], Domínio: Produção, Similaridade: 0.5961
- Nome: ID_Materia_Prima, Labels: ['Column'], Domínio: Produção, Similaridade: 0.5954
- Nome: VendasContext, Labels: ['Concept'], Domínio: None, Similaridade: 0.5940

```

Figura 37 – Caso 9 - Elementos relevantes do grafo (Fonte: Autor)

- Repostas do LLM: Figura 38

```

--- QUERY SQL GERADA PELO LLM ---
SELECT
  P.*,
  CP.Nome_Categoria,
  R.ID_Receita
FROM Produto AS P
INNER JOIN Categoria_Produto AS CP
  ON P.ID_Categoria_Produto = CP.ID_Categoria_Produto
LEFT JOIN Receita_Produto AS R
  ON P.ID_Produto = R.ID_Produto;
--- FIM DA QUERY ---

```

Figura 38 – Caso 9 - Query gerada pelo LLM (Fonte: Autor)

- **Explicação do LLM para a Query:** Tabela 5

Tabela 5 – Caso de uso 9: Explicação LLM

Explicação do LLM
Explicação da Lógica da Query: A query acima retorna um relatório completo de produtos, incluindo informações de tabelas relacionadas. Ela utiliza ‘JOINS’ para combinar dados da tabela ‘Produto’ com outras tabelas que possuem relacionamentos com ela, baseados nas chaves estrangeiras (FKs) definidas no esquema. 1. **‘SELECT P.*, CP.Nome_Categoria, R.ID_Receita’**: Esta cláusula seleciona todas as colunas da tabela ‘Produto’ (indicado por ‘P.*’), além da coluna ‘Nome_Categoria’ da tabela ‘Categoria_Produto’ e ‘ID_Receita’ da tabela ‘Receita_Produto’. Isso fornece um relatório completo com informações de categorias e se o produto possui uma receita associada. 2. **‘FROM Produto AS P’**: Define a tabela ‘Produto’ como a tabela principal da consulta, usando o alias ‘P’ para simplificar a escrita da query. 3. **‘INNER JOIN Categoria_Produto AS CP ON P.ID_Categoria_Produto = CP.ID_Categoria_Produto’**: Esta cláusula realiza um ‘INNER JOIN’ entre as tabelas ‘Produto’ e ‘Categoria_Produto’. Um ‘INNER JOIN’ retorna apenas as linhas onde existe correspondência entre as colunas especificadas na condição ‘ON’. Neste caso, a junção é feita usando ‘ID_Categoria_Produto’, que é uma chave estrangeira em ‘Produto’ referenciando a chave primária em ‘Categoria_Produto’. Isso garante que apenas produtos com categorias registradas sejam incluídos no relatório. 4. **‘LEFT JOIN Receita_Produto AS R ON P.ID_Produto = R.ID_Produto’**: Esta cláusula realiza um ‘LEFT JOIN’ entre a tabela resultante do ‘INNER JOIN’ anterior e a tabela ‘Receita_Produto’. Um ‘LEFT JOIN’ retorna todas as linhas da tabela da esquerda (‘Produto’ neste caso), mesmo que não haja correspondência na tabela da direita (‘Receita_Produto’). Se um produto não tiver uma receita associada, os campos de ‘Receita_Produto’ serão preenchidos com ‘NULL’. A junção é feita usando ‘ID_Produto’, que é uma chave estrangeira em ‘Receita_Produto’ referenciando a chave primária em ‘Produto’. Em resumo, a query combina informações de três tabelas para fornecer um relatório abrangente de produtos, incluindo seus nomes, descrições, preços, categorias e IDs de receitas associadas, se existirem. A utilização de ‘INNER JOIN’ e ‘LEFT JOIN’ garante que todas as informações relevantes sejam incluídas no relatório, tratando adequadamente os casos onde um produto pode ou não ter uma receita associada.

- **Resultados da Execução da Query (LLM vs Gabarito):** Figura 39²⁷ e Figura 40²⁸

Consulta SQL executada com sucesso. Retornou 4 registros.

SQL Gerado e Executado. Resultados:

ID_Produto	Nome_Produto	Descricao_Produto	Preco_Unitario_Venda	ID_Categoria_Produto	Nome_Categoria	ID_Receita
201	Quadríciclo X-Treme	Veículo off-road de alta performance.	35000	1	Veículos	
202	Mochila Voadora AeroPack	Mochila pessoal com propulsão a jato.	120000	2	Equipamentos Voadores	
203	Bike Montanha Carbono	Bicicleta leve para trilhas agressivas.	8000	1	Veículos	701
204	Capacete Adventure Pro	Capacete com sistema de comunicação.	1500	3	Acessórios	

Figura 39 – Caso 9 - Retorno da consulta gerada pelo LLM (Fonte: Autor)

Caso de Uso 9: Demonstração e Execução dos Casos de Uso (Relatório Completo de Produto com Relações)

```

query_example = """
SELECT
  P.*,
  CP.*,
  R.*,
  IP.*,
  E.*,
  OP.*
FROM Produto AS P
INNER JOIN Categoria_Produto AS CP
  ON P.ID_Categoria_Produto = CP.ID_Categoria_Produto
LEFT JOIN Receita_Produto AS R
  ON P.ID_Produto = R.ID_Produto
LEFT JOIN Item_Pedido AS IP
  ON P.ID_Produto = IP.ID_Produto
LEFT JOIN Estoque AS E
  ON P.ID_Produto = E.ID_Produto
LEFT JOIN Producao_Ordem AS OP
  ON P.ID_Produto = OP.ID_Produto;
"""
print("Executing example query:")
run_query_and_display(query_example, conn)

```

Executing example query:

	ID_Produto	Nome_Produto	Descricao_Produto	Preco_Unitario_Venda	ID_Categoria_Produto	ID_Categoria_Produto	Nome_Categoria	ID_Receita	ID_Produto	ID_Item_Pedido	...	Preco_Venda	ID_Estoque	ID_Produto	Quantidade_Disponivel
0	201	Quadríciclo X-Treme	Veículo off-road de alta performance.	35000.0	1	1	Veículos	NaN	NaN	1.0	...	35000.0	1.0	201.0	50.0
1	201	Quadríciclo X-Treme	Veículo off-road de alta performance.	35000.0	1	1	Veículos	NaN	NaN	4.0	...	35000.0	1.0	201.0	50.0
2	202	Mochila Voadora AeroPack	Mochila pessoal com propulsão a jato.	120000.0	2	2	Equipamentos Voadores	NaN	NaN	2.0	...	120000.0	2.0	202.0	10.0
3	203	Bike Montanha Carbono	Bicicleta leve para trilhas agressivas.	8000.0	1	1	Veículos	701.0	203.0	3.0	...	8000.0	NaN	NaN	NaN
4	204	Capacete Adventure Pro	Capacete com sistema de comunicação.	1500.0	3	3	Acessórios	NaN	NaN	NaN	...	None	NaN	NaN	NaN

5 rows x 16 columns.

Figura 40 – Caso 9 - Retorno da consulta gabarito (Fonte: Autor)

- **Análise dos resultados:** Este cenário demonstrou a capacidade do sistema em gerar uma consulta SQL complexa, agregando informações de múltiplas tabelas relacionadas. O LLM foi capaz de interpretar a solicitação de um relatório completo e de fazer relação (*join*) com as tabelas que tiverem relações, unindo a tabela **Produto** com **Categoria_Produto** (via *INNER JOIN*) e com **Receita_Produto** (via *LEFT JOIN*), trazendo as colunas relevantes (*P.**, *CP.Nome_Categoria*, *R.ID_Receita*). No entanto, observou-se que o LLM não conseguiu identificar e incluir todas as relações de segundo nível ou mais distantes que a pergunta genericamente solicitava (“com as tabelas que tiverem relações e me traga as colunas delas também”), conforme evidenciado pela diferença em comparação com a *golden query*. A resposta do LLM se restringiu às relações diretas mais óbvias ou aquelas que foram priorizadas

²⁷ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQUX>

²⁸ Figuras em resolução ampliada disponíveis em: <https://shre.ink/SQUh>

semanticamente na busca no grafo. Este resultado destaca a eficácia do sistema em lidar com relações de primeiro nível e junções explícitas, mas também aponta uma limitação na capacidade atual do LLM em explorar grafos de conhecimento com múltiplos saltos para construir consultas mais abrangentes ou em inferir a profundidade de relações desejada pelo usuário sem um direcionamento mais explícito.

4.3 Considerações do experimento

O presente capítulo detalhou a avaliação experimental da abordagem proposta, demonstrando a funcionalidade do protótipo desenvolvido para a gestão do conhecimento corporativo. Os casos de uso simulados validaram a capacidade do sistema de traduzir perguntas em linguagem natural para consultas SQL, com foco em sua acurácia e relevância contextual. A arquitetura centralizada em um grafo de conhecimento mostrou-se eficaz em fornecer a camada semântica e contextual necessária para o raciocínio do LLM, agindo como um *proxy* que prioriza a segurança ao expor apenas metadados, e não os dados sensíveis.

O sistema validou sua robustez em lidar com consultas complexas de múltiplos *JOINS*. Um aprendizado crucial foi a capacidade do protótipo em reconhecer a ausência de conexões de dados, abstendo-se de gerar respostas incorretas, o que reforça sua confiabilidade para uso em ambientes de produção. Além disso, a aplicação da ontologia demonstrou a habilidade do sistema em interpretar conceitos abstratos do domínio de negócio, traduzindo-os em filtros de busca acionáveis.

A tabela 6, a seguir, resume os objetivos e resultados de cada caso de uso, fornecendo um panorama claro da validação da proposta.

Tabela 6 – Casos de uso e resultados

Caso de Uso	Objetivo	Resultado Esperado	Sucesso?
Caso de uso 1	Testar múltiplos JOINS entre tabelas de diferentes domínios.	Gerar uma query SQL que consolida dados de lançamentos, contas e centros de custo.	Sim
Caso de uso 2	Testar o sistema com uma conexão de dados inexistente entre domínios.	O LLM deve reconhecer a ausência de conexão e não gerar a query SQL.	Sim

Continua na próxima página

Tabela 6 – Casos de uso e resultados

Caso de Uso	Objetivo	Resultado Esperado	Sucesso?
Caso de uso 3	Validar novamente a capacidade de reconhecer a falta de conexão entre tabelas.	O LLM deve indicar a impossibilidade de gerar a query SQL devido à falta de relacionamento.	Sim
Caso de uso 4	Demonstrar o uso da ontologia para interpretar conceitos de negócio.	O LLM deve utilizar a ontologia para traduzir o conceito "produtos voadores" em uma query funcional.	Sim
Caso de uso 5	Testar a capacidade de governança de dados (mascaramento de campo).	O sistema deve mascarar um campo sensível com base em metadados.	Não
Caso de uso 6	Testar uma jornada de dados completa, com múltiplos JOINS para uma visão 360°.	O sistema deve gerar uma query SQL complexa com LEFT JOINS que inclui todos os produtos.	Sim
Caso de uso 7	Testar a capacidade de consultar o meta-conhecimento.	O LLM deve raciocinar sobre as relações da tabela Produto e retornar uma contagem.	Sim
Caso de uso 8	Testar a capacidade de consultar o meta-conhecimento para todas as relações.	O sistema deve fornecer um panorama completo das relações da tabela Produto.	Não
Caso de uso 9	Testar a capacidade de uso da ontologia e JOINS para um relatório completo de produto.	O LLM deve gerar uma query com JOINS baseada na ontologia para um relatório completo.	Sim

5 CONCLUSÕES E TRABALHOS FUTUROS

5.1 O desafio original e propósitos delineados

A presente jornada de pesquisa foi impulsionada por uma questão fundamental: **como transformar a vasta quantidade de informações disponíveis nas organizações em conhecimento verdadeiramente útil e acionável?** Observou-se que, apesar da explosão informacional, muitas vezes as empresas lutam para extrair valor de seus próprios dados.

Diante desse cenário, delineou-se o propósito central de explorar e propor uma abordagem que pudesse fluir o conhecimento, desde sua absorção e circulação até o compartilhamento, entre diferentes esferas: entre humanos e sistemas inteligentes (inter-agentes) e entre os próprios seres humanos (intra-agentes). Priorizou-se que essa potencialização acontecesse em consonância com princípios essenciais de governança, segurança e ética informacional, abraçando o ciclo completo da transformação do conhecimento, da socialização à internalização.

5.2 As conquistas e os aprendizados no caminho

A abordagem proposta, fundamentada na integração da Ciência da Informação com o PLN por meio de um grafo de conhecimento, demonstrou ser um caminho eficaz para potencializar a circulação do conhecimento organizacional. A construção do protótipo validou a viabilidade de transformar perguntas em linguagem natural em consultas estruturadas e acionáveis, especificamente no formato SQL.

Observou-se que a CI, com seu vasto arcabouço teórico e prático em curadoria, organização, representação e governança da informação, revela-se indispensável para a potencialização da circulação do conhecimento quando combinada ao PLN. A CI fornece a estrutura e a inteligência para converter dados brutos e conhecimento tácito em ativos de conhecimento explicitamente modelados (grafos e ontologias), os quais são então eficientemente aproveitados pelas tecnologias de PLN, como LLMs e modelos de *embeddings*. Sem essa base conceitual e metodológica da CI, o PLN operaria com contexto limitado ou desorganizado, comprometendo a qualidade e acurácia das respostas.

A espiral do conhecimento, conforme o modelo SECI, foi coberta e suportada pelas etapas do protótipo e pelo fluxo metodológico da pesquisa, abrangendo os seus quatro processos de conversão do conhecimento:

- A **Socialização**, embora não automatizada pelo protótipo em sua captura direta, é o ponto de partida essencial e habilitador do processo. Os artefatos de entrada do

protótipo (modelo lógico, metadados de governança e ontologia) são, por natureza, o resultado da socialização e da interação entre especialistas de domínio e arquitetos de informação. Esses arquivos explicitam o conhecimento tácito compartilhado e consolidado em modelos formais, criando a base para as etapas subsequentes.

- A **Externalização** e a **Combinação** foram centralmente demonstradas pelo protótipo. A injeção de metadados do modelo lógico e da ontologia no grafo de conhecimento ilustrou a externalização de conhecimento tácito em formas explícitas, tornando-o acessível e processável por máquinas. A fase de Combinação foi materializada pela integração do esquema do banco de dados relacional, da ontologia e dos metadados de governança em um único grafo, que serviu como uma linguagem ubíqua para o LLM. Este grafo permitiu que o LLM combinasse diferentes fontes de conhecimento para formular respostas precisas e contextualmente ricas em formato SQL.
- A **Internalização** é facilitada de maneira crucial pelo sistema. A execução bem-sucedida das *queries* geradas pelo LLM no banco de dados SQLite simulado validou a capacidade do sistema em traduzir a intenção complexa do usuário em uma consulta acionável. Mais importante, a entrega da *query* SQL acompanhada de uma explicação detalhada da sua lógica permite que o usuário não apenas obtenha a informação, mas também compreenda a estrutura dos dados e o raciocínio por trás da consulta. Essa compreensão facilita a absorção do conhecimento explícito e sua transformação em conhecimento tácito individual, capacitando o usuário a formular perguntas mais complexas ou até mesmo a criar suas próprias consultas futuramente. Adicionalmente, a Etapa 6 da metodologia, que prevê a retroalimentação da plataforma com *prompts* e artefatos gerados, demonstra a internalização do conhecimento explicitado de volta para o sistema, aprimorando continuamente sua base de conhecimento e desempenho.

Um aprendizado crucial emergiu da validação do protótipo: a importância de não apenas gerar consultas precisas, mas também de **identificar quando uma conexão de dados não é clara ou direta**. O protótipo demonstrou a capacidade de informar ao usuário a impossibilidade de gerar uma consulta SQL em cenários de dados desconectados ou ambigualmente relacionados, conforme instruído no *prompt* do LLM. Este comportamento é vital para a confiabilidade de sistemas de *Text-to-SQL* em ambientes corporativos.

Por fim, uma conquista fundamental desta abordagem reside na segurança e privacidade dos dados. Ao entregar aos LLMs apenas representações de metadados, esquemas e conhecimento ontológico (contexto semântico) em vez dos dados transacionais ou documentos brutos, o protótipo mitiga significativamente os riscos de exposição de informações sensíveis. O grafo de conhecimento atua como um *proxy* inteligente que fornece o contexto para o raciocínio do LLM, enquanto a execução real das consultas permanece em um

ambiente controlado, sem a externalização dos dados primários. Esta característica representa um diferencial relevante para a adoção em organizações com rigorosos requisitos de governança e segurança da informação.

5.3 Contribuições deste estudo

O presente estudo oferece contribuições significativas tanto para a pesquisa acadêmica quanto para a aplicação prática no contexto do mercado corporativo, no campo da Ciência da Informação e da Inteligência Artificial. A abordagem desenvolvida visa não apenas avançar o conhecimento teórico, mas também fornecer um modelo pragmático para organizações que buscam otimizar a gestão e o acesso ao seu capital informacional.

Em primeiro lugar, demonstra-se a **viabilidade e a eficácia de uma abordagem integrada** que une o arcabouço conceitual da Ciência da Informação, os princípios da Gestão do Conhecimento e as capacidades de PLN para enfrentar o desafio da circulação do conhecimento em ambientes organizacionais. A materialização dessa integração em um protótipo funcional, capaz de traduzir perguntas em linguagem natural para consultas SQL acionáveis em um banco de dados relacional, serve como uma prova de conceito robusta para futuras implementações em larga escala no setor produtivo.

Uma contribuição central reside na aplicação e validação do **Grafo de Conhecimento como camada intermediária inteligente**. Ao invés de expor diretamente o esquema de um banco de dados relacional complexo aos LLMs, o estudo propõe e implementa a construção de um grafo de conhecimento rico em metadados — incluindo o modelo lógico, a ontologia do domínio e metadados de governança — com *embeddings* vetoriais. Essa camada semântica e contextual permite que o LLM raciocine sobre a estrutura dos dados e as relações entre as entidades de forma mais abstrata e eficaz, facilitando a geração de SQL preciso e contextualizado. A utilização de *embeddings* e similaridade de cosseno para recuperar elementos relevantes do grafo em função da pergunta do usuário é um diferencial que otimiza o contexto fornecido ao LLM e se traduz em maior acurácia e relevância para a tomada de decisão empresarial.

Adicionalmente, uma contribuição fundamental é a capacidade do sistema de operar com **segurança e privacidade de dados aprimoradas**. Ao fornecer aos LLMs apenas representações de metadados, esquemas e conhecimento ontológico, e não os dados transacionais ou documentos brutos em si, o protótipo minimiza os riscos de exposição de informações sensíveis. Essa abordagem estabelece o grafo de conhecimento como um *proxy* inteligente que habilita o raciocínio do LLM, enquanto a execução real das consultas e o acesso aos dados primários permanecem em um ambiente controlado da organização, aspecto de vital importância para a conformidade (como a LGPD) e a segurança corporativa, que são preocupações prementes no mercado atual.

O trabalho também contribui ao ilustrar como os princípios da **governança de dados**, especialmente aqueles preconizados pelo DAMA-DMBOK, podem ser incorporados ao grafo de conhecimento na forma de metadados enriquecedores. Embora o protótipo foque na disponibilização desses metadados, sua inclusão no modelo de conhecimento demonstra um caminho para sistemas mais inteligentes que possam, no futuro, aplicar ativamente políticas de governança e metadados de catálogo de dados em processos de negócio automatizados, impactando a qualidade e a confiabilidade das informações usadas por empresas.

Por fim, este estudo oferece um exemplo prático de como o **modelo SECI** da Gestão do Conhecimento, pode ser mapeado e operacionalizado por meio de tecnologias de Inteligência Artificial. Isso ocorre com particular ênfase nas fases de Externalização e Combinação, ao transformar conhecimento (seja ele de modelos lógicos ou ontologias) em estruturas explícitas e combináveis para o raciocínio computacional. Essa operacionalização acelera a curva de aprendizado das organizações e a inovação baseada em dados, pontos críticos para a competitividade no mercado.

5.4 As limitações da abordagem

Embora o presente estudo tenha demonstrado a viabilidade e o potencial de uma abordagem integrada para a gestão do conhecimento, é fundamental reconhecer as limitações inerentes ao escopo de um protótipo e de uma pesquisa desta natureza. Tais limitações não invalidam os resultados obtidos, mas balizam as fronteiras da aplicação atual e servem como direcionadores para trabalhos futuros.

Uma primeira limitação reside na representação e tratamento do conhecimento tácito. Conforme o modelo SECI, a Socialização e a Externalização do conhecimento tácito são processos fundamentais para a criação e compartilhamento. O protótipo, em sua implementação, assume que os artefatos de entrada (como o modelo lógico, os metadados de governança e a ontologia) são o resultado de um processo prévio de socialização e externalização, onde o conhecimento tácito de especialistas já foi consolidado em formatos explícitos e estruturados. A automação da captura direta e da transformação profunda do conhecimento tácito (proveniente de fontes como conversas, reuniões ou *insights* não documentados) não foi o foco principal nem parte do escopo do protótipo, representando uma simplificação necessária para a prova de conceito.

Adicionalmente, a aplicação dos *frameworks* de governança e gestão da informação no protótipo demonstra uma limitação em sua profundidade operacional. Embora os princípios do DAMA-DMBOK tenham sido incorporados através da injeção de metadados de governança nos nós do grafo de conhecimento (como classificação de confidencialidade e proprietário dos dados), o sistema não implementa ativamente os processos dinâmicos de governança de dados. Não há demonstração de validação automatizada de qualidade de

dados em tempo de execução, *workflows* de aprovação de metadados, ou a aplicação granular de políticas de acesso e mascaramento baseadas nesses metadados, o que representaria uma camada de complexidade adicional fora do escopo inicial. Observou-se, inclusive, que o LLM apresentou desafios em inferir e aplicar regras de mascaramento sem uma ferramenta ou instrução explícita no contexto, ressaltando a necessidade de componentes mais específicos para essa finalidade.

Outra limitação relevante refere-se à especificação de dados. A pesquisa fundamenta-se teoricamente na ODPS como um ideal para padronização e consumo eficiente de dados por IAs. Contudo, a implementação prática do protótipo não utilizou o formato YAML nem seguiu as especificações operacionais do ODPS para a representação dos produtos de dados. Optou-se, por pragmatismo e restrições de tempo, por empregar ontologias em OWL/RDF e a estruturação de metadados diretamente no grafo de conhecimento (Neo4j) como os mecanismos primários de especificação semântica e combinação do conhecimento.

No que tange à avaliação experimental, os testes foram conduzidos com um conjunto limitado de casos de uso sintéticos, formulados para demonstrar a funcionalidade e a viabilidade da abordagem. Embora a execução bem-sucedida das queries SQL geradas no ambiente de banco de dados simulado confirme a funcionalidade do sistema, essa validação primariamente qualitativa e funcional não constitui uma avaliação quantitativa rigorosa. Métricas de desempenho em larga escala, comparação com *benchmarks* estabelecidos ou estudos com usuários reais não foram realizados, aspectos que demandariam um esforço e tempo substancialmente maiores.

Finalmente, a robustez da solução para lidar com grandes volumes de dados não-estruturados em sua forma original é uma área não explorada diretamente pelo protótipo. O sistema foca na interação com um esquema de banco de dados relacional e uma ontologia (formas de dados estruturados ou semi-estruturados) e na interpretação de perguntas do usuário em linguagem natural. A capacidade de processar, extrair e inferir conhecimento de documentos textuais brutos (como relatórios extensos, e-mails ou transcrições de reuniões) para enriquecer automaticamente o grafo de conhecimento não foi implementada, representando um escopo para aprofundamento futuro.

5.5 Trabalhos futuros

A presente pesquisa estabelece uma base sólida para futuras investigações e desenvolvimentos no campo da integração entre Ciência da Informação e Inteligência Artificial para a gestão do conhecimento. As limitações identificadas no protótipo, em particular, apontam para direções estratégicas que podem enriquecer a abordagem proposta.

Em primeiro lugar, um aprimoramento substancial reside na validação quantitativa rigorosa do sistema. Sugere-se a criação de um dataset de teste abrangente, composto por

um número significativo de pares de perguntas em linguagem natural e suas respectivas *queries* SQL de gabarito (*golden queries*), formuladas por especialistas do domínio. A métrica primária de avaliação seria a acurácia de resultados, que compararia os conjuntos de dados retornados pelas *queries* geradas pelo sistema com aqueles produzidos pelas *queries* de gabarito. Essa abordagem permitiria uma medição objetiva do desempenho do sistema em escala e a comparação com outras abordagens existentes na literatura.

Outra avenida promissora é o aprofundamento na integração e automação de processos de governança de dados. Futuras pesquisas poderiam explorar a inclusão de componentes que implementem ativamente as políticas de governança, como mascaramento dinâmico de dados sensíveis ou validação automatizada da qualidade de dados em tempo de execução, utilizando os metadados contextuais disponíveis no grafo de conhecimento. A investigação de *tools* específicas para LLMs que permitam a aplicação de regras de governança de forma programática e contextual seria um avanço relevante.

Adicionalmente, expandir a capacidade de captura e externalização automatizada do conhecimento tácito representa um próximo passo crucial. Isso envolveria o desenvolvimento de pipelines de PLN para processar e extrair automaticamente entidades, relações e *insights* de documentos não-estruturados, como transcrições de reuniões, e-mails, wikis corporativas ou relatórios técnicos. A alimentação contínua do grafo de conhecimento com essas informações fecharia o ciclo do modelo SECI de forma mais completa, transformando ativamente o conhecimento tácito em explícito para ser consumido pelos sistemas de IA.

Nesse contexto de dados não-estruturados, destaca-se a possibilidade de validação cruzada de conhecimento. Propõe-se a investigação de módulos de inferência que comparem os resultados de *queries* SQL (obtidos de dados estruturados) com informações extraídas de fontes não-estruturadas (como documentos ou transcrições). Esse mecanismo permitiria validar, complementar ou contextualizar dados quantitativos com narrativas qualitativas, explorando o potencial de raciocínio e inferência entre fontes de conhecimento heterogêneas.

Para aprimorar a robustez do grafo de conhecimento, sugere-se um aprofundamento em pesquisas sobre modelos conceituais. Isso incluiria a exploração de metodologias e padrões para a construção de ontologias e grafos de conhecimento mais abrangentes e formalmente rigorosos. Paralelamente, o estudo de estratégias de *embeddings* e buscas semânticas mais aprimoradas é pertinente, investigando diferentes modelos de *embeddings* (incluindo aqueles específicos para domínios ou multimodais) e técnicas avançadas de busca vetorial para otimizar a recuperação de contexto para os LLMs.

Finalmente, a expansão da aplicabilidade da solução para outros Sistemas Gerenciadores de Banco de Dados (SGBDs) relacionais, ou até mesmo para bases de dados NoSQL e o desenvolvimento de uma interface de usuário mais amigável, representam desdobramentos práticos que potencializariam a adoção da abordagem em cenários corporativos diversificados.

REFERÊNCIAS

- ALLOUCH, M.; AZARIA, A.; AZOULAY-SCHWARTZ, R. Conversational agents: Goals, technologies, vision and challenges. **Sensors (Basel, Switzerland)**, v. 21, p. 8448, 2021. Disponível em: <https://www.mdpi.com/1424-8220/21/24/8448>.
- CASELI, H. M.; NUNES, M. G. V. **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 2. ed. BPLN, 2024. 796 p. Catalog. ISBN 978-65-00-95750-1. Disponível em: <https://brasileiraspln.com/livro-pln/2a-edicao/>.
- DAMA. **Data Management Body Of Knowledge**. [S.l.: s.n.]: Technics Publications, 2017. 628 p. Catalog.
- DAVENPORT, T. H. **Ecologia da Informação**. [S.l.: s.n.]: Editora Futura, 1998. 316 p. Catalog.
- EVANS, E. **Domain-driven design**. [S.l.: s.n.]: Alta Books, 2016. 528 p. Catalog.
- GUIZZARDI GIANCARLO E GUARINO, N. **Explanation, semantics, and ontology**. [S.l.: s.n.], 2024. Disponível em: <https://ris.utwente.nl/ws/portalfiles/portal/466045729/1-s2.0-S0169023X24000491-main.pdf>. Acesso em: 12 abr. 2025.
- LI, J. *et al.* A survey on recent advances in named entity recognition from deep learning models. *In: Proceedings of the 27th International Conference on Computational Linguistics (COLING)*. Association for Computational Linguistics, 2018. p. 2145–2158. Disponível em: <https://aclanthology.org/C18-1182/>.
- LIU, P. *et al.* A survey on open information extraction from rule-based model to large language model. *In: Findings of the Association for Computational Linguistics: EMNLP 2024*. Association for Computational Linguistics, 2024. p. 9586–9608. Disponível em: <https://aclanthology.org/2024.findings-emnlp.560/>.
- MINAEE, S. *et al.* Large language models: A survey. **arXiv:2402.06196v3 [cs.CL]**, 2025. Disponível em: <https://www.semanticscholar.org/paper/Large-Language-Models%3A-A-Survey-Minaee-Mikolov/a1f76db91c0debcf93ae9889736bce8470902113>.
- MOILANEN, J.; SORG, M. **OPEN DATA PRODUCT SPECIFICATION**. [S.l.: s.n.], 2024. Version v3.1. Disponível em: <https://opendataproductions.org/v3.1/#introduction>. Acesso em: 12 abr. 2025.
- NONAKA, I. **the Knowledge-Creating Company**. [S.l.: s.n.], 2008. Acesso em: 12 abr. 2025.
- S., S.; STUDER, R. **Handbook on Ontologies**. 2. ed. [S.l.: s.n.]: Springer, 2009. 832 p. Catalog. ISBN 978-3-540-70999-2.
- ZHAO, X. *et al.* A comprehensive survey on relation extraction: Recent advances and new frontiers. **ACM Computing Surveys (CSUR)**, v. 1, 2024. Disponível em: <https://dl.acm.org/doi/10.1145/3674501>.